



Universiteit Utrecht

Topicsgeneratie in Ricgraph

definitieve scriptie: Vrijdag 25 september 2026

Naam: Daan Romijn

Studentnummer:

Opleiding: Business IT & Management

Hogeschool Utrecht

Begeleider/Tweede examiner: Jeffrey Matray

Eerste examiner: Marco Terlouw

Bedrijfsbegeleider: David Grote Beverborg

Samenvatting

De Universiteit Utrecht maakt gebruik van het systeem Ricgraph om onderzoeksinformatie uit geïsoleerde bronsystemen met elkaar te verbinden. Momenteel ontbreekt het veel publicaties aan uniforme classificatie. Bestaande trefwoorden zijn veelal handmatig ingevoerd, incompleet en onderhevig aan auteur-bias. Het doel van dit onderzoek is het selecteren, evalueren en integreren van een geautomatiseerde AI-aanpak die via een Large Language Model (LLM) objectief en reproduceerbaar OpenAlex-topics toekent aan publicaties. De hoofdvraag luidt: Welke LLM-gebaseerde aanpak voor topicgeneratie presteert het beste voor de classificatie van publicaties binnen Ricgraph, en hoe kan deze worden geïntegreerd in de Ricgraph-keten en gebruikersinterface?

Het onderzoek startte met een systeemanalyse (IST- en SOLL-situatie) op basis van een semigestructureerd interview met de Product Owner, documentanalyses en code-reviews. Voor de selectie van het LLM is het SFA-model gebruikt. De technische uitvoering en evaluatie vonden plaats in een experimentele Proof of Concept (POC) op basis van de SCRUM-methode. De reproduceerbaarheid van drie modelconfiguraties (waaronder Llama 3 en gpt-oss-120b) werd getest op 924 abstracts met vijf iteraties per abstract. De onderlinge overlap van de gegenereerde topics werd statistisch geëvalueerd met behulp van de Jaccard-index.

Uit de initiële analyse bleek dat het huidige proces bestond uit gefragmenteerde scripts zonder structurele weergave in de front-end. Binnen de ontwikkelde POC is een geautomatiseerde datapijplijn gerealiseerd, inclusief een werkende zoekfunctie in de Ricgraph Explorer. Uit de kwantitatieve testresultaten bleek dat het *gpt-oss-120b* model met een temperatuur van 0.1 de hoogste reproduceerbaarheid behaalde (een Jaccard-index van 0,7873). Dit model vertoonde echter wel de langste verwerkingstijd en was gevoeliger voor technische fouten dan de onderzochte alternatieven.

De configuratie van het *gpt-oss-120b* model met een temperatuur van 0.1 presteert het beste voor de topicclassificatie binnen Ricgraph, omdat deze de hoogste stabiliteit levert. Dit model is via de ontwikkelde Proof of Concept functioneel geïntegreerd in de keten. Gebruikers kunnen via de gerealiseerde interface met behulp van logische AND-relaties filteren op toegewezen topics om onderzoekers en publicaties inzichtelijk te maken.

De validiteit van dit onderzoek is gewaarborgd door het hanteren van een kwantitatief evaluatiekader met een vaste dataset. Een beperking is het ontbreken van een absolute *ground truth*. Het onderzoek toetst de reproduceerbaarheid van de modellen, maar valideert niet of de geselecteerde topics inhoudelijk accuraat zijn voor het betreffende vakgebied. De langere verwerkingstijd en de foutgevoeligheid van *gpt-oss-120b* vormen een technisch aandachtspunt, maar belemmeren het proces in de praktijk niet wegens de eenmalige aard van de classificatie per publicatie.

Om de efficiëntie en accuratesse te verhogen, wordt aanbevolen om het LLM de OpenAlex-topics direct te laten genereren in plaats van deze achteraf te matchen. In de gebruikersinterface wordt een dynamisch filtermechanisme geadviseerd om lege zoekresultaten te voorkomen. Voor het waarborgen van schaalbaarheid is de implementatie van asynchrone batchverwerking noodzakelijk. Tot slot wordt een kwalitatief vervolgonderzoek met domeinexperts aanbevolen om de inhoudelijke validiteit van de LLM-toewijzingen te toetsen.

1 Inhoudsopgave

Samenvatting	1
1 Inleiding.....	4
2 Context.....	5
2.1 Achtergrond.....	5
2.2 Organisatorische context.....	5
2.3 Stakeholders	6
2.3.1 Macht/belang-matrix	6
2.4 Kwestie	7
2.5 Doel.....	8
2.6 Afbakening.....	9
2.7 Onderzoeksvragen.....	9
2.8 Producten	10
2.8.1 Onderzoeksverslag (scriptie).....	10
2.8.2 POC.....	10
3 Theoretisch kader/Literatuuronderzoek.....	11
3.1 Mindmap	11
3.2 Begrippen	12
3.2.1 Artificiële intelligentie en topic generatie.....	12
3.2.2 Onderzoekssystemen.....	14
3.2.3 Onderzoeksmethoden.....	16
4 Methodologie.....	19
4.1 Deelvraag 1	19
4.2 Deelvraag 2	19
4.3 Deelvraag 3	20
4.4 Deelvraag 4.....	21
5 Resultaten	23
5.1 Deelvraag 1	23
5.1.1 Context.....	23
5.1.2 Huidige werking.....	23
5.1.3 Data Flow Diagram (DFD)	25
5.1.4 Geïdentificeerde bottlenecks en knelpunten	25
5.2 Deelvraag 2	26
5.2.1 Requirements overzicht	26
5.2.2 IST-SOLL gap analyse	28

5.3	Deelvraag 3	29
5.3.1	Longlist	29
5.3.2	Shortlist	31
5.3.3	SFA model.....	32
5.3.4	Definitieve modelkeuze voor de Proof of Concept.....	34
5.4	Deelvraag 4.....	35
5.4.1	Testresultaten repeatability.....	35
5.4.2	Inter-model vergelijking.....	36
5.4.3	Samenvatting modelprestaties	36
5.4.4	Realisatie van de Proof of Concept (POC) en UI-koppeling	36
6	Conclusie	39
7	Discussie.....	40
7.1	Beperkingen.....	40
7.2	Aanbevelingen voor vervolgonderzoek.....	41
8	Aanbevelingen	42
8.1	Directe toewijzing van OpenAlex-topics door het LLM:.....	42
8.2	Dynamische resultaatfiltering in de Ricgraph Explorer	42
8.3	Implementatie van batchverwerking ter prestatieverbetering	42
8.4	Verbreding en kwaliteitscontrole van de invoerdata.....	43
	Literatuurlijst/Bibliografie.....	44
9	Bijlage 1: Interview (PO) R. Janssen, 23-03-2026.....	47
10	Bijlage 2: Transcripties interviews gebruikers	53
	Interview B. Schaart, 09-04-2026	53
	Interview T. Veken, 17-04-2026:.....	62
	Interview R. Lacroix, 24-04-2026:	68
11	Bijlage 3: Interview D. (David) Grote Beverborg (Begeleider), 07-05-2026:	79
12	Bijlage 4: Testplan: Evaluatie LLM-classificatie.....	88
12.1	Opzet	88
12.1.1	Doel van de test	88
12.1.2	Testdata (Dataset)	88
12.1.3	Testopstelling en Configuratie	88
12.1.4	Uitvoering en Meetsystematiek (Repeatability).....	89
12.1.5	Dataverwerking en Resultaten	89
12.2	Methode	90
12.2.1	Meetsystematiek: Paarsgewijze Jaccard-vergelijking.....	90
12.2.2	Meetsystematiek: Inter-model Jaccard-vergelijking	90

1 Inleiding

De Universiteit Utrecht werkt aan de continue verbetering van de zichtbaarheid en vindbaarheid van wetenschappelijke output. Het systeem Ricgraph (Research in context graph) vervult hierin een centrale rol door gefragmenteerde onderzoeksinformatie uit verschillende bronsystemen samen te voegen in een centrale graafdatabase. Hierdoor kunnen nieuwe relaties tussen onderzoekers, publicaties en projecten worden ontdekt.

Om de functionaliteit van Ricgraph te vergroten, is er behoefte aan een uniforme manier om publicaties te groeperen op onderwerp. Momenteel ontbreekt het veel publicaties aan trefwoorden, of de bestaande trefwoorden zijn sterk onderhevig aan de subjectieve voorkeur van de auteur. Dit onderzoek richt zich op de ontwikkeling van een geautomatiseerd, AI-gedreven classificatieproces op basis van Large Language Models (LLM's). Het doel is om een betrouwbare methode te ontwerpen en te evalueren die, vrij van auteur-bias, gestandaardiseerde onderzoekstopics toekent aan wetenschappelijke abstracts. Tevens is het doel om deze functionaliteit werkend te integreren in de gegevensverwerkingsketen en de gebruikersinterface (Explorer) van Ricgraph, zodat eindgebruikers efficiënt kunnen filteren op interdisciplinaire onderzoeksgebieden.

Leeswijzer

Dit onderzoek is opgebouwd uit verschillende hoofdstukken. In hoofdstuk 2 wordt de context van de opdracht toegelicht, inclusief de organisatorische achtergrond, de onderzoekskwestie, het doel en de onderzoeksvragen. In hoofdstuk 3 wordt het theoretisch kader geschetst, waarbij kernconcepten zoals LLM's, topicgeneratie, reproduceerbaarheid en het relationele datamodel van Ricgraph worden besproken. Hoofdstuk 4 beschrijft de toegepaste methodologie, waaronder de testopzet en het iteratieve ontwikkelproces van de Proof of Concept (POC). In hoofdstuk 5 worden de resultaten gepresenteerd aan de hand van de huidige situatie (IST), de gewenste situatie (SOLL), de modelselectie en de daadwerkelijke prestaties uit de evaluatie. Hoofdstuk 6 geeft de conclusie en beantwoordt de hoofdvraag. In hoofdstuk 7 worden de resultaten en beperkingen van het onderzoek bediscussieerd, waarna hoofdstuk 8 tot slot de concrete aanbevelingen presenteert voor de doorontwikkeling van het systeem.

2 Context

2.1 Achtergrond

De Universiteit Utrecht genereert dagelijks een grote hoeveelheid wetenschappelijke output, waaronder publicaties, datasets en software. Om deze onderzoeksactiviteiten inzichtelijk te maken ontwikkelt de directie Information and Technology Services (ITS) het systeem Ricgraph (Research in context graph). Dit systeem voegt onderzoeksinformatie uit diverse geïsoleerde bronsystemen (zoals Pure en Yoda) samen. Hierdoor ontstaan nieuwe relaties die in de afzonderlijke systemen onzichtbaar blijven, zoals interdisciplinaire samenwerkingen tussen onderzoekers en projecten.


Om deze data beter doorzoekbaar te maken, is er behoefte aan 'topics': gestructureerde trefwoorden die eenduidig aangeven over welk onderzoeksgebied een publicatie gaat. Omdat het handmatig toekennen van deze topics aan de grote hoeveelheid publicaties in Ricgraph niet schaalbaar is, wordt gewerkt aan een geautomatiseerde oplossing. Hierbij wordt Artificial Intelligence (AI) ingezet om de complexe, wetenschappelijke taal in abstracts te analyseren en automatisch de juiste topics toe te wijzen. Dit stelt onderzoekers, beleidsmakers en ondersteunend personeel in staat om sneller inzicht te krijgen in expertise, trends en samenwerkingen.

Bij de uitvoering hiervan bleek dat er nog geen betrouwbare, reproduceerbare methode bestaat om deze topics consistent te genereren. Daarnaast zijn de toegekende topics nog niet zichtbaar in de bestaande gebruikersinterface. Het doel van deze opdracht is om een geschikte AI-aanpak te selecteren, te evalueren en werkend te integreren binnen Ricgraph.

2.2 Organisatorische context

De Universiteit Utrecht is een grote onderwijs- en onderzoeksinstelling met ruim 7.000 medewerkers. In haar missie stelt de universiteit zich expliciet ten doel om complexe maatschappelijke vraagstukken te onderzoeken over de grenzen van disciplines heen (Utrecht, Universiteit, n.d.). Thema's zoals klimaatverandering en gezond leven vereisen een interdisciplinaire aanpak, waarbij kennis vanuit verschillende faculteiten wordt verbonden om noodzakelijke transformaties richting te geven.

Binnen de universiteit is de directie Information and Technology Services (ITS) verantwoordelijk voor de centrale ICT-diensten ter ondersteuning van deze visie. Het ontbreken van een overkoepelend informatiesysteem zorgt er momenteel voor dat onderzoeksinformatie versnipperd blijft in decentrale silo's. Dit belemmert de universiteit direct in haar missie: zolang data niet gecentraliseerd en uniform geclassificeerd is, blijven kansen voor interdisciplinair onderzoek over de grenzen van disciplines heen onopgemerkt. Deze opdracht vindt plaats binnen de afdeling Research and Data Management Services (RDMS), onderdeel van het cluster Applications, die zich bezighoudt met de ontsluiting van deze onderzoeksdata via het project Ricgraph.



Figuur 1 - Organogram UU

Het afstudeeronderzoek vindt plaats binnen dit project. Ricgraph slaat onderzoeksinformatie op in een node-edge datamodel, waarbij onderzoekers, publicaties en projecten als knooppunten worden verbonden. De relevante ICT-aspecten voor deze opdracht zijn het Ricgraph systeem met dit datamodel, de koppeling met de gebruikersinterface, en het gebruik van LLM's (Large Language Models) voor het verwerken en verrijken van onderzoeksinformatie.

Naast het inhoudelijke onderzoek zal de student ook de backlog beheren en de scrum ceremonies rondom dit project met het team organiseren.

Een gerelateerd project dat gelijktijdig speelt is de ontwikkeling van een AI-chatbot voor het opvragen van informatie uit Ricgraph. Het topics systeem zal hier uiteindelijk ook in opgenomen worden, maar valt buiten de scope van dit project.

2.3 Stakeholders

Voor de succesvolle inzet van Ricgraph en het geautomatiseerde topicproces is een divers speelveld van stakeholders relevant. Om de invloed en belangen van deze actoren inzichtelijk te maken, is onderstaande stakeholderanalyse opgesteld.

STAKEHOLDER	BELANG
RICGRAPH-TEAM	Besluit over scope, prioritering en de definitieve model- en configuratiekeuze. Ook verantwoordelijk voor verdere ontwikkeling na afloop project
ITS	Moet de Proof of Concept kunnen onderhouden en integreren in de bestaande, veilige dataverwerkingsketen van de universiteit
EINDGEBRUIKERS	Bruikbaarheid van de zoekfunctionaliteit: filtering, transparantie over herkomst, correctiemogelijkheden en het ontdekken van interdisciplinaire vakgenoten
EXTERNE PARTIJEN (JOURNALISTEN, BELEIDSMAKERS)	Het snel kunnen vinden van de juiste academische experts binnen een actueel thema
ANDERE ONDERZOEKINSTELLINGEN	Hebben baat bij het ontdekken van overlappend onderzoek en vakgenoten aan de UU via topics
OVERHEID / SUBSIDIEVERSTREKKERS	Belang bij Open Science-naleving en een aantoonbare, transparante onderzoeksclassificatie als verantwoording voor bestede publieke financiering
OPENALEX EN ANDERE LEVERANCIERSYSTEMEN	Leveren de brondata en de classificatiestandaard waarvan de kwaliteit en beschikbaarheid het hele proces bepalen

Tabel 1 - Stakeholders

2.3.1 Macht/belang-matrix

Om te bepalen hoe met deze verschillende groepen moet worden omgegaan tijdens en na de ontwikkeling, zijn de stakeholders gepositioneerd in een macht/belang-matrix (gebaseerd op Mendelow).

STAKEHOLDER	MACHT	BELANG
-------------	-------	--------

RICGRAPH-TEAM	Hoog	Hoog
ITS	Gemiddeld	Gemiddeld
EINDGEBRUIKERS	Beperkt	Hoog
EXTERNE PARTIJEN (JOURNALISTEN, BELEIDSMAKERS)	Laag	Laag (nu)
ANDERE ONDERZOEKINSTELLINGEN / EXTERNE ONDERZOEKERS	Laag	Gemiddeld
OVERHEID / SUBSIDIEVERSTREKKERS	Gemiddeld	Laag
OPENALEX EN ANDERE LEVERANCIERSSYSTEMEN	Hoog (functionele afhankelijkheid)	Laag (geen strategisch belang bij deze leveranciers zelf)

Tabel 2 - Macht/belang-matrix stakeholders

Uit deze analyse blijkt dat het Ricgraph-team de belangrijkste speler is voor dit onderzoek, zij sturen de functionele en technische keuzes. Systemen zoals OpenAlex hebben een hoge macht wegens de sterke functionele afhankelijkheid van hun API en thesaurus, maar eisen geen actieve communicatie. De eindgebruikers hebben een hoog belang bij een werkend systeem, maar een beperkte formele macht over de technische realisatie. Voor de acceptatie van het systeem is het echter goed om deze groep nauw betrokken te houden.

2.4 Kwestie

Ricgraph koppelt onderzoeksinformatie, zoals publicaties, organisaties en onderzoekers, uit meerdere bronsystemen en leidt daaruit automatisch nieuwe verbanden af die in de afzonderlijke systemen niet zichtbaar zijn. Hoewel specifieke bronsystemen vaak al eigen trefwoorden hanteren, zijn deze classificaties versnipperd over verschillende standaarden, regelmatig afwezig, of sterk onderhevig aan de subjectieve voorkeur (bias) van de auteur. Om de verzamelde data in Ricgraph overkoepelend te kunnen verbinden, is een uniforme en onafhankelijke classificatielaag wenselijk. Door alle publicaties, ongeacht hun oorsprong, te voorzien van topics uit één gestandaardiseerde thesaurus, worden betrouwbare dwarsverbanden gecreëerd die vrij zijn van auteur-bias.

Deze gestandaardiseerde topic-toekenning maakt concrete, overkoepelende zoekvragen mogelijk die in geïsoleerde systemen onbeantwoord blijven voor verschillende gebruikersgroepen:

Voor onderzoekers: Het ontdekken van vakgenoten aan andere universiteiten die, via gedeelde co-auteurs en gezamenlijke topics, raakvlakken hebben met hun eigen onderzoeksvelden.

Voor ondersteunend personeel (zoals bibliothecarissen): Het identificeren van publicaties binnen een specifiek topic die wel in externe netwerken staan, maar nog ontbreken in het lokale onderzoeksinformatiesysteem (RIS), om zo het profiel van de universiteit te completeren.

Voor externe partijen (zoals journalisten of beleidsmakers): Het gericht en snel vinden van de juiste experts en hun publicaties binnen een actueel thema (zoals klimaatverandering of stamcelonderzoek) voor media-optredens of kennisdeling.

Het niet oplossen van dit classificatieprobleem heeft directe gevolgen voor de effectiviteit van de organisatie. Zonder uniforme topics blijft waardevolle onderzoeksinformatie moeilijk vindbaar, wat leidt tot een aanzienlijk verlies van kostbare onderzoekstijd. Uit onderzoek blijkt dat het

identificeren, ophalen en structureren van bronnen voor een meta-analyse gemiddeld 588 uur kost. Ook voor een reguliere systematische review (SR) neemt de pure zoekfase al snel gemiddeld 23 tot 24 uur in beslag (Bullers, et al., 2018). Door de vindbaarheid van publicaties via een gestandaardiseerde topic-toekenning in Ricgraph te vergroten, kan deze intensieve, administratieve zoektijd naar relevante bronnen en vakgenoten drastisch worden gereduceerd.

Naast deze aanzienlijke tijdsbesparing levert de implementatie overkoepelende, kwalitatieve opbrengsten op. Wanneer de tool actief door onderzoekers wordt gebruikt, vergroot dit de zichtbaarheid van interdisciplinair onderzoek. Dit vertaalt zich op termijn naar een toename in samenwerkingen en een verhoging van het aantal citaties in wetenschappelijke papers, wat de academische reputatie van de universiteit versterkt. Ook levert dit onderzoek de organisatie een fundamentele, theoretisch onderbouwde strategie op voor de inrichting van het classificatieproces. Hoewel de doorlooptijd van een dergelijk academisch vooronderzoek aanzienlijk is, is deze investering in ontwikkeltijd belangrijk. De resulterende geautomatiseerde classificatie garandeert een betrouwbare toewijzing van trefwoorden, wat de universiteit in staat stelt om veel accuratere selecties en analyses uit te voeren binnen zowel de lokale als de bredere Nederlandse onderzoeksdata.

Het handmatig toekennen van topics aan de grote hoeveelheid publicaties in Ricgraph is niet schaalbaar, daarom wordt gewerkt aan een uitbreiding waarbij dit automatisch gebeurt. Concreet worden hiervoor de abstracts van publicaties als invoer gebruikt, dit zijn de beknopte samenvattingen waarin auteurs de kern van hun onderzoek beschrijven. Omdat deze publicaties zijn opgebouwd uit complexe, contextgevoelige wetenschappelijke terminologie, volstaan traditionele 'supervised learning' algoritmen of eenvoudige trefwoordherkenning niet. Waar eenvoudigere modellen vastlopen op letterlijke tekstherkenning of vereisen dat het ontwikkelteam eerst duizenden voorbeelden handmatig labelt, is een voorgetraind Large Language Model (LLM) in staat om de werkelijke semantische betekenis van een tekst te doorgronden. Hierbij is het een harde voorwaarde dat het LLM niet zelf willekeurige topics verzint, maar de inhoud uitsluitend classificeert aan de hand van een vooraf gedefinieerde, gestandaardiseerde thesaurus (de OpenAlex-topics).

Er bestaat op dit moment een eerste opzet voor dit proces, maar deze kent twee tekortkomingen. Ten eerste is het gebruikte LLM-model (Meta Llama 3 8B Instruct) gekozen zonder onderbouwing en zonder te testen of het de meest geschikte oplossing is voor dit specifieke toepassingsgeval. Het is daardoor onduidelijk of de huidige modelkeuze en configuratie voldoende nauwkeurig en reproduceerbaar zijn voor structurele inzet. Ten tweede worden de gegenereerde topics niet opgeslagen in Ricgraph: de output bestaat uit een CSV-bestand waar verder niets mee gedaan wordt, waardoor topics niet zichtbaar zijn in Ricgraph Explorer (de interactieve website/UI van Ricgraph) en gebruikers er niet op kunnen zoeken of filteren. Met op dit moment 85.044 publicaties in de publieke demo vertegenwoordigt dit een grote hoeveelheid onderzoeksinformatie die zonder werkende topicgeneratie moeilijk doorzoekbaar blijft.

Beide tekortkomingen samen vormen de aanleiding voor dit project: enerzijds het onderbouwd selecteren en evalueren van een geschikte LLM-aanpak, anderzijds het realiseren van een werkende integratie binnen de Ricgraph-keten en gebruikersinterface.

2.5 Doel

Het doel van dit project is om binnen Ricgraph een betrouwbaar en reproduceerbaar (consistent dezelfde resultaten opleverend) LLM-gebaseerde topicgeneratie te ontwerpen, te evalueren en te realiseren in een Proof of Concept (POC), zodanig dat topics consequent aan publicaties kunnen worden toegekend en doorzoekbaar worden in Ricgraph Explorer. Dit wordt bereikt door (1) de

huidige classificatie van publicaties in kaart te brengen, (2) de functionele en technische eisen voor dit proces te bepalen en te prioriteren, (3) geschikte LLM-modellen met bijbehorende configuraties te selecteren en (4) deze te evalueren op basis van vooraf gedefinieerde, meetbare criteria met name reproduceerbaarheid, gemeten via de Jaccard-index, zodat één best presterende combinatie onderbouwd kan worden geselecteerd en geïntegreerd in de Ricgraph-keten en gebruikersinterface.

Het project is geslaagd wanneer:

- Een zoekinterface in Ricgraph Explorer is gerealiseerd waarmee gebruikers kunnen filteren op topics. De gebruiker kan een selectie maken van maximaal tien topics (bepaald door de opdrachtgever) waarna (a) de bijbehorende publicaties worden weergegeven en (b) alle personen die aan deze publicaties gekoppeld zijn zichtbaar worden, via een logische AND-relatie tussen de gekozen topics.
- Voor de topicgeneratie worden de topics uit OpenAlex gebruikt: een open database voor wetenschappelijke publicaties die een gestructureerde topicclassificatie biedt (OpenAlex, 2026).
- De best presterende methode voor het genereren van topics is gerealiseerd en functioneel binnen de Ricgraph-keten.
- Een scriptie is opgeleverd waarin de onderzoeksresultaten en de onderbouwing van gemaakte keuzes uitgebreid zijn gedocumenteerd.
- Alle code en bijbehorende documentatie, inclusief de scriptie, op een goed gedocumenteerde manier beschikbaar zijn gesteld in een UU GitHub-repository.

2.6 Afbakening

De scope van dit project wordt nadrukkelijk beperkt:

Processen: Alleen de processen rondom het genereren en toekennen van topics worden onderzocht. Andere toepassingen/wijzigingen (zoals chatbotintegratie, zoekoptimalisatie, etc.) vallen buiten de scope.

Systemen: De focus ligt volledig op Ricgraph, het topicsproces en de koppeling met de bestaande UI. Andere onderzoeks-informatiesystemen worden enkel in context meegenomen.

Fasen: Het project omvat onderzoek naar de beste methode voor de topics generatie en de realisatie van een werkende UI-koppeling om de resultaten zichtbaar en testbaar te maken. Een volledige productieklare implementatie of breder adviesopdracht maakt geen deel uit van dit project. Ook valt onderhoud of beheer buiten de scope.

2.7 Onderzoeksvragen

Hoofdvraag:

Welke LLM-gebaseerde aanpak voor topicgeneratie presteert het beste voor de classificatie van publicaties binnen Ricgraph, en hoe kan deze worden geïntegreerd in de Ricgraph-keten en gebruikersinterface?

Deelvragen:

1. Hoe werkt de huidige classificatie van publicaties binnen Ricgraph? (IST)
2. Waar moet een LLM-gebaseerde aanpak voor topic generatie en classificatie van publicaties aan voldoen? (SOLL)
3. Welke LLM-modellen en welke configuraties daarvan sluiten het beste aan bij het topicsproces gegeven de eisen uit de SOLL situatie?
4. Wat is de best presterende combinatie van LLM-model en configuratie wanneer de selectie uit deelvraag 3 objectief wordt getoetst in een Proof of Concept?

2.8 Producten

De producten van deze stage zijn een scriptie en een POC.

2.8.1 Onderzoeksverslag (scriptie)


In de scriptie wordt het volledige onderzoeksproces gedocumenteerd. Dit omvat de analyse van relevante LLM-modellen en toepassingsmethoden, de opzet en uitvoering van de experimenten, het vergelijken en interpreteren van de resultaten en de onderbouwing van de uiteindelijke keuze voor de best presterende aanpak.

2.8.2 POC

Deze laat zien welke LLM-model- en configuratiecombinatie het best presteert voor de automatische generatie van topics binnen Ricgraph. De POC bestaat uit een uniforme opzet waarin geselecteerde modellen met verschillende configuraties worden getest op een set publicaties, op basis van een vooraf opgesteld evaluatiekader met meetbare criteria. Op basis hiervan wordt de best presterende combinatie geselecteerd en deze blijft geïmplementeerd, zodat deze blijvend kan worden gebruikt binnen het topicsproces. De POC levert daarnaast een eenvoudige UI-koppeling op waarmee de gegenereerde topics zichtbaar worden in de bestaande Ricgraph interface. Alle code, configuraties en documentatie worden beschikbaar gemaakt in de GitHub repository, zodat de POC volledig transparant en reproduceerbaar is.

3 Theoretisch kader/Literatuuronderzoek

3.1 Mindmap



Figuur 2 - Mindmap vooronderzoek

Figuur 2 geeft een overzicht van de centrale begrippen die relevant zijn voor dit onderzoek, gestructureerd vanuit het centrale thema: AI topicgeneratie binnen onderzoekssystemen. De mindmap is opgedeeld in drie hoofdtakken. De linker tak behandelt de onderzoeksmethoden, onderverdeeld in informatie ophalen, analyse en testen. De onderste tak richt zich op onderzoekssystemen, met Ricgraph als kernsysteem en de bijbehorende technische componenten zoals de Explorer/UI, Graph database en het node-edge model. De rechter tak behandelt AI en LLM's, met aandacht voor modellen, modelconfiguraties en topicgeneratie. In de volgende paragrafen worden de meest relevante begrippen uit deze takken nader toegelicht.

3.2 Begrippen

3.2.1 Artificiële intelligentie en topic generatie

Een centraal thema binnen dit onderzoek is artificiële intelligentie en hoe deze gebruikt wordt voor het genereren van topics.

3.2.1.1 Artificiële intelligentie en Large Language Models

Artificiële intelligentie (AI) is de capabiliteit van een computer om taken uit te voeren die traditioneel geassocieerd zijn met menselijke intelligentie, zoals leren, redeneren, problemen oplossen, waarnemen en beslissingen maken. Het is een onderzoeksveld in de informatiekunde dat methodes en software onderzoekt en ontwikkelt waarmee machines hun omgeving kunnen waarnemen en door te leren en intelligentie acties kunnen ondernemen met de grootste kans op het behalen van het doel (Russell & Norvig, 2021). Binnen dit project betekent dit specifiek dat het systeem in staat moet zijn om natuurlijke taal (wetenschappelijke teksten) te analyseren en daar betekenis aan te geven.

Het probleem waar AI voor ingezet wordt binnen dit project is namelijk de verwerking van grote hoeveelheden data, met name de abstracts van publicaties. De beslissing die het systeem moet maken, is het bepalen welke topics uit de OpenAlex-vocabulair het beste passen bij de inhoud van een publicatie. Dit vereist dat het systeem niet alleen specifieke woorden herkent, maar ook de context van het onderzoek begrijpt.

Een specifieke toepassing hiervan zijn Large Language Models (LLM's) dit zijn modellen die via zelf-gesuperviseerde training op grote datasets een statistisch begrip van taal ontwikkelen, waardoor het in staat is om context-afhankelijke tekst te genereren en diverse taken uit te voeren zonder taak-specifieke herprogrammering (Patil & Gudivada, 2024). Zoals in de inleiding is toegelicht, maakt deze brede algemene kennis voorgetrainde LLM's bij uitstek geschikt voor het verwerken van academische teksten binnen Ricgraph. Het model kan direct relaties leggen tussen de context van een publicatie en een topic, zonder dat er vooraf een grootschalige, handmatig gelabelde dataset nodig is om het algoritme te trainen.

Het onderzoeksveld rondom Large Language Models kenmerkt zich door een hoog tempo van technologische innovatie (Mohammed & Kora, 2025). Dit resulteert in een grote diversiteit aan modellen die aangeboden worden die fundamenteel kunnen verschillen in architectuur, toegankelijkheid en trainingsdoeleinden.

Een belangrijk verschil tussen modellen is de mate van openheid. Commerciële 'Closed Source'-modellen (zoals de GPT-4 familie van OpenAI) bieden vaak hoogstaande prestaties via een API, maar vereisen dat data extern verwerkt wordt. Daartegenover staan 'Open Weights'-modellen (zoals de LLaMA-reeks van Meta), die lokaal op eigen hardware kunnen draaien. (Minaee, et al., 2025)

Niet elk model is gebouwd voor dezelfde taak. Generatieve modellen zijn ontworpen om menselijke conversatie na te bootsen en tekst te produceren (decoder-only architectuur). Daarnaast bestaan er modellen die specifiek getraind zijn om semantische overeenkomsten te berekenen, de zogenaamde Sentence Transformers (encoder-architectuur). (Reimers & Gurevych, 2019)

Cosine similarity (Sarwar, 2001) is een wiskundige maatstaf die wordt gebruikt om te berekenen hoe vergelijkbaar twee documenten of teksten zijn. In dit onderzoek wordt het gebruikt om de overlap tussen de gevectoriseerde abstract van een publicatie en een OpenAlex-topic te meten, hoe hoger de score, hoe sterker de semantische overeenkomst.

Deze variabelen zijn bepalend voor de toepasbaarheid van een model binnen Ricgraph. In dit onderzoek wordt daarom getoetst hoe deze specifieke eigenschappen zich verhouden tot de eisen die in deelvraag 2 worden vastgesteld zoals beschreven in de aanpak.

3.2.1.2 Topicgeneratie met LLM's

Een specifieke toepassing van Large Language Models binnen dit onderzoek is topicgeneratie. In tegenstelling tot traditionele classificatiemodellen die getraind zijn op vooraf gedefinieerde categorieën, wordt bij LLM's gebruikgemaakt van 'prompting'. Hierbij wordt het model via natuurlijke taal geïnstrueerd om de essentie van een ongestructureerde tekst (zoals een abstract) samen te vatten in kernwoorden.

Binnen de context van dit project is het genereren van willekeurige kernwoorden echter onvoldoende. De gegenereerde topics moeten aansluiten bij de gestructureerde data van OpenAlex. Het model dient niet alleen de tekst te begrijpen, maar ook de inhoud te mappen op een bestaande thesaurus of gecontroleerde vocabulaire. Dit stelt specifieke eisen aan de prompting-strategie: het model moet gestuurd worden om termen te kiezen die valide zijn binnen de OpenAlex-topics, in plaats van vrij associatieve termen te verzinnen die niet bestaan in de database.

Een fundamentele eigenschap van LLM's die hierbij een uitdaging vormt, is hun probabilistische aard (Shyr, et al., 2025). LLM's berekenen de statistische waarschijnlijkheid van het volgende woord in een reeks. Dit betekent dat de output per definitie variabel kan zijn; dezelfde input kan op verschillende momenten tot net iets andere antwoorden leiden. Voor wetenschappelijke toepassingen en databeheer is dit problematisch, omdat reproduceerbaarheid een vereiste is. Als een publicatie vandaag topic A krijgt en morgen topic B, is het systeem onbetrouwbaar voor de eindgebruiker.

Om deze variabiliteit te beheersen en de modellen te optimaliseren voor deze specifieke toepassing, kunnen verschillende configuraties van hetzelfde model worden gebruikt. Parameters zoals temperature, top probability (top p), frequency penalty en presence penalty hebben veel invloed op het outputgedrag en zijn cruciaal om aan te passen aan de use case (Arora, Sayeed, Licorish, Wang, & Treude, 2024).

Temperature reguleert de 'creativiteit' of willekeur van het model. Voor het toekennen van vaste topics is een lage temperatuur essentieel om de output zo deterministisch (voorspelbaar) mogelijk te maken en 'hallucinaties' te voorkomen.

Daarnaast is het beheer van tokens van belang. Het model heeft een beperkt 'context window'. Er moet voldoende ruimte zijn om zowel de uitgebreide prompt (met instructies over de OpenAlex-structuur) als de volledige abstract te verwerken.

Het correct afstellen van deze parameters vormt de sleutel tot het succesvol inzetten van een LLM voor clusteren en benoemen: het transformeert een creatieve tekstgenerator in een betrouwbare classificatietool.

3.2.1.3 Reproduceerbaarheid als kwaliteitsaspect

Om de gegenereerde topics evalueren is de reproduceerbaarheid van de resultaten de belangrijkste beoordelingsfactor binnen dit onderzoek. In deze context betekent dat om met dezelfde methode en input consistent dezelfde resultaten te behalen (Gundersen & Kjensmo, 2018) (National Academies of Sciences, 2019). Bij de inzet van Large Language Models voor topicgeneratie vormt dit een specifieke uitdaging. Omdat LLM's van nature probabilistisch zijn, kunnen deze bij identieke prompts verschillende antwoorden genereren (Shyr, et al., 2025). Voor Ricgraph is dit een probleem, als het systeem bij een herhaalde analyse van hetzelfde abstract op verschillende momenten andere topics toekent, tast dit de validiteit van bibliometrische analyses en de betrouwbaarheid voor de eindgebruiker aan.

Een complicatie bij het evalueren van deze modellen is dat er voor wetenschappelijke abstracts vaak geen eenduidige 'ground truth' of gouden standaard beschikbaar is. Er is immers niet één objectief juist rijtje topics dat bij een tekst hoort, wat inhoudelijke validatie bemoeilijkt. Hierdoor verschuift de focus van de kwaliteitsborging naar de stabiliteit van het proces en daarmee het model. De reproduceerbaarheid wordt in deze context getoetst door de mate van overeenkomst tussen meerdere opeenvolgende runs van het proces met dezelfde data, hetzelfde model en dezelfde configuratie te meten. Een effectieve methode om deze consistentie objectief te kwantificeren is het gebruik van de Jaccard-index, waarmee de overlap tussen de verzamelingen gegenereerde topics berekend wordt. Deze statistische benadering maakt het mogelijk om de variabiliteit van een model te vangen in een meetbare waarde, zonder dat daar een vooraf gedefinieerd correct antwoord voor nodig is. (Niawattanakul, Singthongchai, Naenudorn, & Wanapu, 2013)

De mate waarin een model reproduceerbaar presteert, hangt nauw samen met de interactie tussen de prompting-strategie en de technische parameters zoals de temperature. Zoals zal worden beschreven in de aanpak van dit onderzoek, is het minimaliseren van de temperatuur de primaire methode om deterministisch gedrag af te dwingen. Toch kunnen ook externe factoren, zoals updates aan commerciële modellen of de hardwarematige verwerking van berekeningen, de stabiliteit beïnvloeden. Dit benadrukt het belang van het evalueren van verschillende modelcombinaties binnen een gestandaardiseerd kader, zoals de LLM Repeatability Test uit het CoLLM-framework (Saadedizade, et al., 2025). Door reproduceerbaarheid als kernwaarde te hanteren, vormt dit evaluatie kader de directe basis voor de Proof of Concept, waarin de best presterende configuratie wordt geselecteerd op basis van objectieve, herhaalbare criteria.

3.2.2 Onderzoekssystemen

Onderzoeksinformatiesystemen, internationaal bekend als Current Research Information Systems (CRIS), vormen de technologische ruggengraat voor het beheer van de onderzoekscyclus binnen een organisatie (euroCRIS, 2024) (De Castro & Hanna-Mari, 2023). Een CRIS verschilt fundamenteel van een traditionele institutionele repository (IR). Waar een repository primair gericht is op het archiveren en ontsluiten van de digitale objecten zelf (zoals PDF-documenten of ruwe datasets), fungeert een CRIS als een relationeel knooppunt dat de context van het onderzoek vastlegt.

Dit relationele karakter wordt vaak gewaarborgd door standaarden zoals CERIF (euroCris, 2012). Echter, moderne toepassingen vereisen een flexibiliteit die verder gaat dan strikte relationele

schema's, waarbij de nadruk verschuift naar de onderlinge verbondenheid van objecten over instellingsgrenzen heen (de Castro, Shearer, & Summann, 2014).

3.2.2.1 Onderzoekssystemen en onderzoeksdata

De integratie van onderzoeksdata in CRIS-systemen stelt hoge eisen aan de kwaliteit en structuur van metadata. Metadata speelt hierbij een dubbele rol: het fungeert als instrument voor validatie en indexering, maar ook als mechanisme voor kwaliteitscontrole en herkomstbeheer (provenance) (Schöpfel, Prost, & Rebouillat, 2017).

Een van de grootste uitdagingen is de granulariteit van de metadata en de versnippering van informatie over verschillende systemen. Persistente identificatoren (PIDs) zijn hierbij essentieel (The National Library of the Netherlands, n.d.). Een DOI (Digital Object Identifier) is een unieke, permanente code die aan een publicatie, dataset of ander onderzoeksobject wordt toegekend, ongeacht waar het object zich bevindt of naartoe verplaatst (The DOI Foundation, 2026). Een ORCID (Open Researcher and Contributor ID) vervult dezelfde functie op onderzoekersniveau, het is een unieke identifier die een onderzoeker eenduidig identificeert, onafhankelijk van naam variaties of institutionele affiliaties (ORCID, n.d.) (Nature, 2009). Door PIDs als ankerpunten te gebruiken, kunnen relaties tussen publicaties en onderliggende data expliciet worden vastgelegd, ook wanneer deze zich in verschillende systemen of silo's bevinden.

Voor de integratie in onderzoeksevaluaties is het daarmee cruciaal dat metadata gestandaardiseerd en rijk genoeg is om deze relaties zichtbaar te maken en te onderhouden.

3.2.2.2 Ricgraph als onderzoeksinformatiesysteem


In dit deel wordt de technologische context beschreven waarin de AI-gebaseerde topicgeneratie wordt toegepast. Hoewel de generatie van topics gebruikmaakt van externe modellen, is de volledige workflow van data-extractie tot de uiteindelijke verrijking en visualisatie ontworpen als een integraal proces binnen de Ricgraph-infrastructuur. Het begrijpen van de architectuur van dergelijke onderzoekssystemen is daarom noodzakelijk om de positionering en relevantie van de AI-laag binnen het ecosysteem te rechtvaardigen.

Ricgraph (Research in Context Graph) hanteert een fundamenteel andere architectuur dan traditionele CRIS-systemen. Waar een systeem als Pure werkt met een relationeel schema (tabellen met attributen), gebruikt Ricgraph een identifier-centrisch node-edge model. De kracht hiervan is dat informatie uit versnipperde bronnen automatisch samenkomt op basis van gedeelde kenmerken.

3.2.2.2.1 Het Node-Edge Model van Ricgraph

In de architectuur van Ricgraph wordt elk uniek element gerepresenteerd als een node. Centraal hieraan is dat ook persistente identificatoren (PIDs) zoals een ORCID of DOI als zelfstandige nodes in de graaf staan. Ricgraph maakt hierbij een belangrijk architecturaal onderscheid: een persoon wordt gerepresenteerd via een centrale person-root node, die fungeert als ankerpunt voor alle aan die persoon gekoppelde identifier-nodes (zoals ORCID, ISNI of een institutionele ID). Wanneer een nieuwe bron (bijv. OpenAlex) dezelfde identifier bevat, wordt deze simpelweg aan de bestaande node gekoppeld, waardoor de graaf organisch groeit (Janssen, 2025) (Fensel, et al., 2020).

Ricgraph example graph



Figuur 3 - Ricgraph voorbeeld grafiek

Binnen dit model gaan ook de topics nodes vormen die via edges aan de DOI's van de relevante publicaties zijn verbonden.

3.2.2.2 Inferentie via gedeelde nodes

Het vermogen van Ricgraph om nieuwe relaties te infereren komt direct voort uit dit model. Als een publicatie (node) verbonden is met een DOI (node), en diezelfde DOI is in een andere bron verbonden met een dataset (node), dan 'weet' de graaf direct dat de publicatie en de dataset bij elkaar horen, zonder dat dit expliciet in één bronsysteem geregistreerd hoeft te zijn (Janssen, 2025).

3.2.3 Onderzoeksmethoden

De succesvolle uitvoering van dit onderzoek vereist het gebruik van gestandaardiseerde methodieken om het onderzoek betrouwbaar en valide te maken. Hier zal worden beschreven welke methoden worden gebruikt en wat deze inhouden.

3.2.3.1 Informatie ophalen

Voor het pure ophalen van informatie zullen binnen dit onderzoek kwalitatieve methoden worden ingezet die gericht zijn op diepgang en transparantie.

Semigestructureerde interviews: Deze methode is theoretisch onderbouwd als een middel om rijke, contextuele data te verzamelen waarbij de interviewer de vrijheid heeft om door te vragen op specifieke knelpunten terwijl een vastgesteld thema wordt gevolgd (Hijmans & Kuyper, 2007). Deze

methode is gekozen om tegelijkertijd de essentiële informatie uit een interview te krijgen en ruimte te laten voor diepgang of opheldering waar nodig.

Documentanalyse en Literatuurreview: Deze methoden dienen om het overzicht van de organisatie en het vakgebied te begrijpen. Theoretisch gezien vormt dit de basis voor onderbouwde besluitvorming door bestaande kennis over de context, topicmodellering en CRIS-architecturen te integreren.

Code- en architectuurreview: Een systematische inspectie van functie en afhankelijkheden in de codebase. Voor het identificeren van onzichtbare bottlenecks in de datastromen.

3.2.3.2 Analyse en requirements

De analysefase maakt gebruik van systemische raamwerken om de huidige en gewenste situaties goed in beeld te kunnen brengen.

Data Flow Diagrams voor systeemmodellering: Een Data Flow Diagram (DFD) is een gestandaardiseerde grafische notatie die de stromen van gegevens binnen een systeem inzichtelijk maakt. Theoretisch fungeert een DFD als een 'visuele datakaart' die een systeem expliciet maakt via processen, datastromen, datastores en externe entiteiten. Cruciaal is hierbij de theoretische nadruk op datastromen en transformaties: het modelleren van hoe data het systeem binnenkomt, wordt verwerkt en opgeslagen, wat de afhankelijkheden en potentiële bottlenecks direct aanwijsbaar maakt (Lucidchart, 2026).

IST-SOLL gap analyse: Dit is een systemische analysemethode waarbij de huidige staat (IST) methodisch wordt vergeleken met de gewenste toekomstige staat (SOLL). Het theoretische doel is niet alleen het identificeren van verschillen, maar het blootleggen van de onderliggende mechanismen en ontbrekende middelen (IT-infrastructuur, kennis, data) die nodig zijn om de doelstellingen te bereiken (Weller, 2023) (Lucidchart, 2026).

Prioritering via MoSCoW: Gebaseerd op de principes van agile requirements engineering, waarbij eisen worden gewogen op basis van hun kritieke impact op de uiteindelijke oplossing (Must, Should, Could, Won't have). Hiermee wordt een duidelijke rangschikking op basis van prioriteit behaald (Van Vliet, 2008).

3.2.3.3 Modelselectie

De selectie van AI-modellen en configuraties wordt onderbouwd door het SFA-model (Janse, 2026) een strategisch raamwerk voor het evalueren van opties vanuit drie perspectieven.

Suitability (Geschiktheid): Beoordeelt in hoeverre de modelkeuze aansluit bij de opgestelde requirements en de aard van de wetenschappelijke data (bijv. begrijpt het model complexe terminologie?).

Feasibility (Haalbaarheid): Analyseert of de organisatie beschikt over de middelen (rekenkracht, budget voor API-kosten, technische expertise) om de strategie uit te voeren.

Acceptability (Acceptabelheid): Richt zich op de risico's, verwachte opbrengsten en de reacties van stakeholders. Dit omvat ethische aspecten en de mate waarin de resultaten betrouwbaar genoeg zijn voor eindgebruikers.

3.2.3.4 Testen en evaluatie

Vanwege de inherente onvoorspelbaarheid van LLM's wordt een statistisch en technisch testraamwerk gehanteerd.

CoLLM Raamwerk: Dit theoretische raamwerk voor de Consistency of Large Language Models is specifiek ontworpen om de betrouwbaarheid van AI in kennis-engineering te kwantificeren. Het onderscheidt Repeatability (stabiliteit onder identieke condities) van Reproducibility (consistentie onder wisselende condities of modellen) (Saeedizade, et al., 2025).

Hierbij wordt gebruikgemaakt van de Jaccard-index om de mate van overeenkomst tussen meerdere output-runs van hetzelfde model en dezelfde configuratie te bepalen. In tegenstelling tot evaluatiemethoden die gebruikmaken van gemiddelden en standaarddeviaties, is deze aanpak geschikt voor situaties waarin geen baseline beschikbaar is. Door deze vaste en herhaalbare evaluatiemethode toe te passen, wordt gewaarborgd dat de tests consistent worden uitgevoerd en dat de resultaten onderling vergelijkbaar en betrouwbaar zijn.

Jaccard-index voor set-similarity: In tegenstelling tot eenvoudige nauwkeurigheidsmetingen, meet de Jaccard-index de overlap tussen twee verzamelingen (sets) van gegenereerde topics :

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

Figuur 4 - Jaccard-index formule

Theoretisch is dit de meest zuivere maatstaf voor consistentie in topicgeneratie, omdat de rekening houdt met zowel de aanwezigheid als de afwezigheid van specifieke termen over meerdere runs (Niwattanakul, Singthongchai, Naenudorn, & Wanapu, 2013).

3.2.3.5 Iteratieve uitvoering

De uitvoering van het onderzoek is gestoeld op de principes van SCRUM, een raamwerk voor empirische procesbeheersing (Srivastava, Bhardwaj, & Saraswat, 2017).

Transparantie en Inspectie: Door te werken in sprints en de resultaten direct te valideren bij stakeholders, wordt gewaarborgd dat technische keuzes (zoals prompt-engineering) direct getoetst worden aan de bruikbaarheid in de praktijk.

Open Science Praktijken: In lijn met de theorie dat transparantie fraude en fouten voorkomt, wordt alle code en methodologie vastgelegd op GitHub. Dit creëert een 'audit trail' die de wetenschappelijke integriteit van het project verzekerd.

4 Methodologie

Dit hoofdstuk beschrijft de toegepaste methodologie om de onderzoeksvragen te beantwoorden. Het onderzoek combineert kwalitatieve methoden (zoals semigestructureerde interviews en documentanalyse) voor de systeemanalyse en het bepalen van de gebruikerseisen, met een kwantitatieve, experimentele testopstelling (Proof of Concept) voor de modevaluatie. Per deelvraag wordt hieronder toegelicht hoe de data is verzameld en geanalyseerd, en hoe de validiteit en betrouwbaarheid van het onderzoek zijn gewaarborgd.

4.1 Deelvraag 1

Hoe werkt de huidige classificatie van publicaties binnen Ricgraph? (IST)

In deze deelvraag is onderzocht hoe de huidige situatie van het topicsproces eruit ziet. Om dit betrouwbaar en volledig in kaart te brengen, is gebruikgemaakt van een combinatie van een semigestructureerd interview met de Product Owner (zie Bijlage 1: Interview (PO) R. Janssen, 23-03-2026) en een systematische code-review. Hoewel het systeem nog niet in productie was genomen, bestond er al een initiële versie. Tijdens de code-review zijn de drie Python-scripts die de bestaande datapijp lijn vormen geanalyseerd. Hierbij is per script op codeniveau vastgesteld welke invoerdata wordt ingelezen, via welke functies en API-aanroepen deze data wordt getransformeerd, en in welk formaat de uitvoer wordt weggeschreven.

De gecombineerde bevindingen uit het interview en de code-review zijn vastgelegd in een Data Flow Diagram (DFD). Dit model maakt de bestaande opzet en datastromen visueel inzichtelijk voor de direct betrokken stakeholders, voornamelijk de Product Owner en het ontwikkelteam binnen ITS.

Deelproducten:

- DFD
- Overzicht van datastromen, afhankelijkheden, bottlenecks.

4.2 Deelvraag 2

Waar moet een LLM-gebaseerde aanpak voor topic generatie en classificatie van publicaties aan voldoen? (SOLL)

In deze deelvraag wordt de gewenste situatie (SOLL) van het topicsproces vastgesteld. Waar de eerste deelvraag zich richtte op de huidige situatie, ligt de focus hier op het definiëren van een betrouwbaar en bruikbaar toekomstperspectief. Dit is gedaan door de behoeften van de stakeholders in kaart te brengen en deze te vertalen naar concrete eisen.

Om de gebruikerswensen helder te krijgen, zijn in totaal vier semigestructureerde interviews gehouden met de beoogde doelgroep (eindgebruikers) en met de begeleider van dit project en ontwikkelaar binnen Ricgraph (zie Bijlage 2: Transcripties interviews gebruikers & Bijlage 3: Interview D. (David) Grote Beverborg (Begeleider), 07-05-2026:). Tijdens deze gesprekken is uitgevraagd wat men onder 'betrouwbaarheid' en 'bruikbaarheid' verstaat en hoe het topicsproces er uit moet zien om waardevol te zijn binnen het gebruik van Ricgraph.

De verkregen input zijn vervolgens verwerkt in een requirements analyse. Hierbij wordt onderscheid gemaakt tussen functionele eisen en technische/niet-functionele eisen. Om te bepalen welke eisen voorrang hebben, wordt de MoSCoW-methode toegepast. Dit wordt gedaan op basis van de input

van en in overleg met de PO. Hiermee worden de eisen gecategoriseerd in Must have's, Should have's, Could have's en Won't have's, wat sturing geeft aan de verdere ontwikkeling.

Tot slot wordt er een IST-SOLL gap analyse uitgevoerd. Hierbij wordt de huidige situatie (uit deelvraag 1) vergeleken met de gewenste eisen. Dit maakt inzichtelijk welke specifieke 'gaten' (gaps) overbrugd moeten worden om het doel te bereiken.

Deelproducten:

- Requirements overzicht
- IST-SOLL gap analyse

4.3 Deelvraag 3

Welke LLM-modellen en welke configuraties daarvan sluiten het beste aan bij het topicsproces gegeven de eisen uit de SOLL situatie?

In deze deelvraag is het doel om te bepalen welke configuraties en welke Large Language Models (LLM's) het meest geschikt zijn om te voldoen aan de eisen die in de vorige deelvraag (SOLL) zijn vastgesteld. Om tot een onderbouwde keuze te komen, is gestart met een literatuur- en documentatiereview. Hierbij werd onderzocht welke modellen en welke toepassingen hiervan beschikbaar zijn en welke het interessantst zijn om in de context van het topicsproces te onderzoeken. Deze review is uitgevoerd aan de hand van een longlist die op basis van de literatuur is opgesteld, waarna via vooraf bepaalde selectiecriteria een shortlist werd gevormd.

De literatuurreview is uitgevoerd via zoekopdrachten in wetenschappelijke databases zoals Google Scholar, met zoektermen gericht op LLM-gebaseerde topicgeneratie, semantische tekstclassificatie en vector store toepassingen. Daarnaast zijn modeldocumentatie van relevante aanbieders zoals Hugging Face, OpenAI en Meta geraadpleegd.

Voor de initiële inventarisatie is eerst een brede longlist opgesteld op basis van modeldocumentatie en onderzoeksliteratuur over vergelijkbare systemen. Om vanuit deze longlist concreet tot een werkbare shortlist te komen, zijn de verzamelde modellen gefilterd aan de hand van de randvoorwaarden uit de SOLL-situatie (deelvraag 2). Modellen fungeerden als uitsluitingscriteria wanneer zij niet voldeden aan de specifieke eisen rondom privacy (voorkeur voor interne/lokale hosting in plaats van ondoorzichtige cloud-API's), schaalbaarheid, en efficiëntie (het vermijden van onnodig grote context windows voor relatief korte abstracts). Modellen die deze initiële schifting doorstonden, vormden de shortlist. Uit deze shortlist is vervolgens aan de hand van een SFA-model de definitieve combinatie van het AI-model en de bijbehorende configuraties geselecteerd. Deze uiteindelijke keuze is in samenspraak en met goedkeuring van de bedrijfsbegeleider gemaakt om het onderzoek zo relevant mogelijk te houden.

Het SFA model is gekozen om op basis van de requirements uit deelvraag 2 het best aansluitende model te kiezen. Deze is hiervoor geschikt omdat het de opties beoordeeld op geschiktheid, haalbaarheid en acceptabiliteit.

Deelproducten:

- Resultaten Literatuur & modeldocumentatie review

- Longlist
- Shortlist
- SFA model
- Keuze model en configuraties

4.4 Deelvraag 4

Wat is de best presterende combinatie van LLM-model en configuratie wanneer de selectie uit deelvraag 3 objectief wordt getoetst in een Proof of Concept?

In deze deelvraag zijn de geselecteerde combinaties van LLM-modellen en bijbehorende configuraties getest op basis van de eisen die in deelvraag 2 zijn vastgesteld. Het doel was om een testomgeving op te zetten waarin verschillende model- en configuratiecombinaties objectief en resultaatgericht met elkaar konden worden vergeleken, zodat de best presterende combinatie uiteindelijk binnen Ricgraph kon worden toegepast.

Aansluitend is een testplan opgesteld waarin de concrete testopzet is uitgewerkt. Dit omvatte onder andere de selectie van testdata, het vastleggen van herhaalbaarheid, het aantal runs per model en de vastlegging van resultaten in testlogs. Omdat Large Language Models van nature variabele output genereren en er binnen deze context geen eenduidige ground truth beschikbaar was om inhoudelijke accuraatheid objectief te beoordelen, lag de focus van de evaluatie specifiek op reproduceerbaarheid.

De reproduceerbaarheid is getest op basis van de LLM Repeatability Test uit het CoLLM-raamwerk. Hierbij is gebruikgemaakt van de Jaccard-index om de mate van overeenkomst tussen meerdere output-runs van hetzelfde model en dezelfde configuratie te bepalen. In tegenstelling tot evaluatiemethoden die gebruikmaken van gemiddelden en standaarddeviaties, was deze aanpak geschikt voor situaties waarin geen baseline beschikbaar was. Door deze vaste en herhaalbare evaluatiemethode toe te passen, is gewaarborgd dat de tests consistent zijn uitgevoerd en dat de resultaten onderling vergelijkbaar en betrouwbaar zijn.

Naast deze reproduceerbaarheidsmeting is gaandeweg het testproces een aanvullende vergelijking uitgevoerd tussen de modellen onderling, op basis van dezelfde Jaccard-index. Waar de reproduceerbaarheidstest de interne consistentie van één model over meerdere runs meet, is hier onderzocht in hoeverre de verschillende modellen bij dezelfde invoer tot vergelijkbare of juist uiteenlopende topic-classificaties kwamen. Deze inter-model vergelijking was niet vooraf in het testplan opgenomen, maar is tijdens de uitvoering toegevoegd als kleinschalig aanvullend onderzoek, en stond los van de centrale reproduceerbaarheidsvraag waarop de beantwoording van deze deelvraag primair was gericht. Het bood echter wel bijkomend inzicht in de mate waarin de modelkeuze inhoudelijk gevolgen had voor de uiteindelijke classificatie-uitkomst.

Vervolgens zijn de geselecteerde modellen en configuraties in de praktijk getoetst aan de hand van dit evaluatiekader. Tijdens de uitvoering van de experimenten zijn alle handelingen en uitkomsten systematisch vastgelegd in testlogs, zodat de prestaties van de verschillende combinaties nauwkeurig konden worden geanalyseerd en vergeleken. De resultaten zijn samengebracht in een overzicht waarin de prestaties van de verschillende model- en configuratiecombinaties tegen elkaar zijn afgezet. Dit overzicht vormde de basis voor de uiteindelijke selectie van de best presterende combinatie.

De technische testopstelling waarin de geselecteerde modellen en configuraties volgens dit evaluatiekader zijn uitgevoerd, vormde het Proof of Concept (POC).

Voor de ontwikkeling van deze technische testopstelling is de SCRUM-methode toegepast. Deze methode was geschikt omdat de implementatie een experimenteel en iteratief karakter had. Door in korte sprints te werken konden ontwerpkeuzes snel worden getest, geëvalueerd en bijgestuurd. SCRUM heeft daarmee bijgedragen aan flexibiliteit, beheersing van risico's en continue afstemming met de eisen die in eerdere deelvragen zijn vastgesteld.

Tijdens de sprints is de gekozen methode in beperkte vorm geïntegreerd in Ricgraph. Dit omvatte onder andere het toevoegen van benodigde componenten, configuraties en aanroepen naar de geselecteerde modellen, alsmede de realisatie van een eenvoudige UI-koppeling waarmee de gegenereerde topics zichtbaar zijn geworden in de bestaande Ricgraph Explorer interface. Alle gemaakte keuzes, aannames en resultaten zijn vastgelegd in de bijbehorende documentatie.

Deelproducten:

- Testplan
- Testlogs
- Resultatenoverzicht
- POC
- UI-koppeling
- Documentatie

5 Resultaten

5.1 Deelvraag 1

Hoe werkt de huidige classificatie van publicaties binnen Ricgraph? (IST)

5.1.1 Context

Uit het interview met R. Janssen (Product owner) Bijlage 1: Interview (PO) R. Janssen, 23-03-2026, is de volgende context over de huidige classificatie van publicaties gebleken.

Binnen de huidige inrichting van Ricgraph vindt de groepering van wetenschappelijke output, zoals publicaties, datasets en software, voornamelijk plaats op basis van metadata (beschrijvende gegevens zoals de titel, de auteur, het publicatiejaar en de abstract). Deze data is afkomstig uit systemen voor onderzoeksinformatiebeheer, waaronder institutionele archieven van de universiteit (zoals Pure en Yoda) en open, wereldwijde wetenschappelijke databases (zoals OpenAlex). Een belangrijk onderdeel van deze metadata zijn de keywords die door auteurs bij de onderzoeksresultaten worden meegeleverd, zoals het label 'machine learning' of 'klimaatverandering' bij een wetenschappelijk artikel.

Deze huidige methode van classificatie kent in de praktijk twee aanzienlijke beperkingen. Ten eerste ontbreekt bij een groot deel van de opgeslagen onderzoeksresultaten elke vorm van trefwoordclassificatie. Dit betekent dat veel publicaties en datasets in de bronsystemen staan geregistreerd zonder enig beschrijvend label, waardoor het systeem ze niet kan clusteren op een overkoepelend onderwerp en ze moeilijk vindbaar zijn. Ten tweede zijn de keywords die wel aanwezig zijn sterk subjectief en gevoelig voor bias, aangezien deze veelal door de auteurs zelf zijn gekozen. Een identieke publicatie zou door een andere onderzoeker van afwijkende labels worden voorzien, wat leidt tot een inconsistente en onvoorspelbare dataset.

Vanwege bestaande inconsistenties ontbreekt in de huidige database een eenduidige manier om onderzoeksresultaten te koppelen. Het topic-proces is toegevoegd om een gestandaardiseerde classificatie toe te passen. Een geautomatiseerd model kent topics toe aan de gehele dataset, wat zorgt voor een consequente toewijzing en handmatige variatie vermindert.

Deze datastructuur maakt analyses over meerdere domeinen mogelijk. Waar traditionele metadata vaak de organisatorische hiërarchie volgt (universiteit, faculteit, departement), verbinden de gestandaardiseerde topics gegevens buiten de formele organisatiestructuur. Dit maakt de onderzoeksoutput voor universiteit brede thema's analyseerbaar, onafhankelijk van de afdeling waar de onderzoekers werken.

5.1.2 Huidige werking

Het proces voor de toewijzing van topics is opgebouwd uit drie opeenvolgende python scripts.

In het eerste script, *create_embeddings_from_openalex_topics.py*, worden de topics via de API uit OpenAlex geëxtraheerd en lokaal opgeslagen in een JSONL-bestand. Daarna leest het script deze data in om de tekstuele eigenschappen per topic om te zetten in numerieke vectoren (embeddings) via het *sentence transformer*-model "all-MiniLM-L6-v2". Deze gegenereerde vectoren worden lokaal opgeslagen in een binair bestand (.npy). Deze output fungeert als de referentiedatabase voor het latere classificatie script, waarin de opgeslagen topic-vectoren via wiskundige vergelijkingen (*cosine similarity*) worden gekoppeld aan de metadata van wetenschappelijke publicaties.

Het daaropvolgende script in het proces, genaamd *get_abstracts_from_openalex.py*, is verantwoordelijk voor het ophalen van ontbrekende wetenschappelijke samenvattingen (abstracts).


Het script is ingericht om lokaal opgeslagen bestanden te scannen en publicaties te identificeren, op basis van hun *Digital Object Identifier* (DOI), waarvan nog geen abstract beschikbaar is. Met behulp van de Python-bibliotheek *pyalex* wordt vervolgens voor deze specifieke DOI's de titel en abstract via de API uit de OpenAlex-database opgevraagd. Deze geëxtraheerde tekstuele data wordt per publicatie lokaal weggeschreven in een tekstbestand (.txt). De verzamelde abstracts vormen in het latere classificatie script de invoerdata.

Het derde en laatste script (*make_keywords_from_dois.py*) sluit de pijplijn af door de daadwerkelijke toewijzing van de topics aan de publicaties uit te voeren. Dit script integreert de output van de voorgaande stappen door de verzamelde tekstbestanden met abstracts in te lezen en deze wiskundig te vergelijken met de lokaal gecachte topic-embeddings. Voor een nauwkeurige classificatie past het script drie afzonderlijke methoden toe, waarvan de resultaten worden gecombineerd. Ten eerste wordt via een volledige tekstanalyse de gehele abstract omgezet in één vector en middels cosine similarity vergeleken met alle beschikbare topic-vectoren. Ten tweede vindt er een aggregatie op zinsniveau plaats, waarbij de abstract wordt opgesplitst in afzonderlijke zinnen. Elke zin wordt individueel gevectoriseerd en vergeleken, waarna de overeenkomstige scores per topic worden opgeteld. Tot slot is er een optionele module geïmplementeerd waarbij een lokaal *Large Language Model* beknopte onderzoekstopics genereert op basis van de tekst. Wanneer deze optie is uitgeschakeld of het model niet beschikbaar is, treedt een fallback-mechanisme in werking dat de hoogst scorende topics uit de eerste twee methoden selecteert. De gegenereerde of geselecteerde termen worden vervolgens via vectorberekeningen gekoppeld aan de meest overeenkomstige, officiële OpenAlex-topics.

De scores uit deze drie methoden worden via een verdeelsleutel gewogen en samengevoegd tot een definitieve set keywords per publicatie. Na een automatische validatie waarbij ongevalideerde termen worden gefilterd tegen de officiële OpenAlex-dataset, exporteert het script de finale resultaten naar CSV- en Excel-bestanden. In deze output worden de publicaties op basis van hun DOI direct gekoppeld aan de bijbehorende OpenAlex topic-namen en ID's, klaar voor verdere verwerking of analyse.

Het huidige classificatieproces functioneert momenteel als een losstaande, lokale opstelling en is nog niet geïntegreerd in een productieomgeving. De drie scripts worden handmatig uitgevoerd en zijn niet afhankelijk van specifieke infrastructuur of hardware. De datapijplijn eindigt bij de export naar CSV- en Excel-bestanden. Er is in de huidige opzet nog geen mechanisme gerealiseerd om deze verrijkte data automatisch in de Neo4j-database van Ricgraph te importeren.

5.1.3 Data Flow Diagram (DFD)



Figuur 5 - Data Flow Diagram IST situatie

5.1.4 Geïdentificeerde bottlenecks en knelpunten

Binnen het huidige dataproces vormt de architectonische inrichting van het classificatieproces de voornaamste bottleneck. Uit de analyse van de IST-situatie zijn drie structurele knelpunten naar voren gekomen die de effectiviteit, schaalbaarheid en operationalisering van de huidige opzet beperken.

5.1.4.1 Ontbreken van een doordachte modelstrategie

Binnen de huidige opzet ontbreekt een formele strategie voor de inzet en methodiek van classificatiemodellen. Er is onvoldoende theoretische en praktische onderbouwing voor de keuze van het specifieke model en de wijze waarop dit model wordt toegepast voor de topic-toewijzing. Zonder een gerichte modelstrategie ontbreekt het noodzakelijke kader om deze nauwkeurigheid en validiteit structureel te kunnen testen. Omdat er voor de toewijzing van academische topics geen eenduidige ground truth beschikbaar is, kan de betrouwbaarheid van de output alleen worden aangetoond via een vooraf gedefinieerd, gestandaardiseerd evaluatieproces (zoals het meten van reproduceerbaarheid). Doordat een dergelijke evaluatiestrategie in de huidige opzet ontbreekt, kan de kwaliteit van de toegekende trefwoorden niet worden gewaarborgd, wat de effectiviteit van de classificatie beperkt.

5.1.4.2 Onvolledige dataverwerkingsketen en gebrek aan systeemintegratie

De datapijplijn vormt geen aaneengesloten of geïntegreerd systeem. Het proces functioneert momenteel als een losstaande, lokale opstelling die handmatig per script moet worden geïnitieerd. Het proces bevindt zich in een testfase en is nog niet ingericht binnen een productieomgeving, waardoor er ook geen sprake is van inzet op specifieke productieniveau hardware. De verwerkingsketen stopt na de uitvoering van de Python-scripts bij de generatie van lokale CSV- en Excel-bestanden. Omdat een geautomatiseerd koppelings- of importmechanisme naar de Neo4j-database van Ricgraph ontbreekt, blijft de verrijkte data geïsoleerd buiten het centrale systeem staan.

5.1.4.3 Ontbreken van gestandaardiseerde visualisatie

Er is binnen de huidige inrichting geen gestandaardiseerde weergave beschikbaar om de resultaten inzichtelijk te maken. De door de AI toegekende topics zijn voor eindgebruikers pas waardevol wanneer de dwarsverbanden tussen de data visueel worden gemaakt. Een onderzoeker, journalist of beleidsmaker wil bijvoorbeeld in één oogopslag kunnen zien welke wetenschappers van verschillende faculteiten aan hetzelfde thema (zoals klimaatverandering) werken, of welke publicaties overlappen in disciplines. Omdat een grafische interface of dashboard momenteel ontbreekt, blijft deze verrijkte data verborgen in de database als een ruwe, technische lijst met codes en termen. Dit vormt een structureel probleem: zonder visualisatie kunnen niet-technische gebruikers de tool niet inzetten voor hun zoekvragen, en mist het ontwikkelteam een toegankelijke manier om visueel te controleren of het LLM de publicaties daadwerkelijk logisch en correct aan elkaar heeft gekoppeld (kwalitatieve verificatie).

5.2 Deelvraag 2

Waar moet een LLM-gebaseerde aanpak voor topic generatie en classificatie van publicaties aan voldoen? (SOLL)

5.2.1 Requirements overzicht

Op basis van de interviews (Bijlage 2: Transcripties interviews gebruikers, Bijlage 3: Interview D. (David) Grote Beverborg (Begeleider), 07-05-2026:) en de opdrachtstelling zijn de volgende requirements opgesteld.

Functionele eisen

#	EIS	BRON	MOSCOW
F1	Het systeem wijst topics toe aan publicaties door het analyseren van de abstract met behulp van een LLM	PVA	Must
F2	Het systeem logt alle testparameters per iteratie (inclusief modelversie, temperature, top-k, prompt en inputvelden) om reproduceerbaarheid te waarborgen.	Begeleider	Must
F3	Het systeem valideert de toegewezen topics aan de hand van het formele OpenAlex topics-vocabulaire.	PVA	Must
F4	Het classificatieproces is volledig geïntegreerd in de standaard dataverwerkingsflow van het doelsysteem.	Begeleider	Should
F5	Het systeem faciliteert een hiërarchische navigatie door de geclassificeerde data (van domein naar veld, subveld en topic).	B. Schaart, T. Veken, R. Lacroix	Could
F6	Het systeem voorziet door AI toegewezen topics van een traceerbaar label of verwijzing naar de toegepaste methodologie.	B. Schaart, T. Veken	Could
F7	Het systeem registreert metadata per toewijzing, waaronder de datum van toekenning en het specifieke model met bijbehorende versie.	T. Veken, Begeleider	Should
F8	Het systeem slaat de initiële, onbewerkte output van het LLM op ten behoeve van latere evaluatiedoeleinden.	Begeleider	Could
F9	De zoekfunctionaliteit faciliteert het gebruik van zowel AND-als OR-operatoren.	B. Schaart	Could
F10	De interface biedt de mogelijkheid om naast de gevalideerde OpenAlex topics ook de onbewerkte LLM-output te visualiseren.	R. Lacroix	Could

F11	Het classificatiemodel accepteert organisatorische context (zoals faculteit of afdeling) als aanvullende inputvariabele.	R. Lacroix	Could
F12	Het systeem toont gerelateerde of nevengeschikte topics (siblings) in de zoekresultaten.	B. Schaart	Could
F13	Het systeem importeert bestaande, door OpenAlex toegewezen topics als referentiedata voor de evaluatie.	Begeleider	Could
F14	De zoekmodule is tolerant voor spelfouten en verwerkt synoniemen.	B. Schaart	Could
F15	Het systeem past een visueel onderscheid toe tussen door AI gegenereerde topics en door de auteur gedefinieerde trefwoorden.	B. Schaart, T. Veken	Won't
F16	De interface presenteert auteur-trefwoorden en AI-toegewezen topics gelijktijdig in één overzicht.	B. Schaart, T. Veken	Won't
F17	Het systeem biedt geautoriseerde gebruikers de functionaliteit om handmatige correcties uit te voeren op toegewezen topics.	T. Veken	Won't
F18	Het systeem baseert de classificatie op de volledige tekst van de publicatie in plaats van uitsluitend de samenvatting.	T. Veken	Won't

Tabel 3 - Functionele eisen uit PVA en interviews

Niet-functionele eisen

#	EIS	BRON	MOSCOW
NF1	Consistentie: Het systeem functioneert consistent waarbij herhaalde uitvoeringen met identieke input resulteren in een aantoonbaar vergelijkbare topic-toewijzing, meetbaar middels de Jaccard-index.	PVA	Must
NF2	Kosten: Het proces minimaliseert financiële risico's door API-verbruik inzichtelijk te maken en vereist een proefuitvoering voorafgaand aan opschaling.	Begeleider	Must
NF3	Privacy: Het classificatieproces verwerkt uitsluitend openbare onderzoeksdata en sluit de verwerking van persoonsgegevens uit.	Begeleider	Must
NF4	Schaalbaarheid: Het systeem is ingericht om zonder fundamentele architectuurwijzigingen datasets van ten minste 3 miljoen publicaties over meerdere organisaties te verwerken.	T. Veken, R. Lacroix, Begeleider	Must
NF5	Performance: Het systeem realiseert een verwerkingssnelheid van minimaal 100.000 publicaties per etmaal tijdens een volledige run.	Begeleider	Must
NF6	Toegankelijkheid: De gebruikersinterface hanteert begrijpelijke, niet-technische terminologie.	B. Schaart	Should
NF7	Transparantie: Het systeem borgt inzichtelijkheid door gebruikers de herkomst, het tijdstip en de bron van een topic-toewijzing te tonen.	T. Veken, B. Schaart	Should
NF8	Automatisering: De dataverwerkingsketen is volledig geautomatiseerd en vereist geen handmatige interventies tussen de processtappen.	Begeleider	Could
NF9	Kwaliteit: Het systeem faciliteert de structurele meting van inhoudelijke accuraatheid van de toegewezen topics.	B. Schaart, T. Veken, R. Lacroix	Won't (nu)

NF10	Taal: Het systeem ondersteunt uitsluitend de Engelse taal voor de classificatie en verwerking van tekst.	B. Schaart	Won't (nu)
-------------	--	------------	------------

Tabel 4 - Niet-functionele eisen uit PVA en interviews

Toelichting per MoSCoW-categorie

Must have: Deze toewijzing is toegekend aan de essentiële kernfunctionaliteiten en randvoorwaarden die strikt noodzakelijk zijn voor het slagen van dit project. Deze eisen zijn primair gedestilleerd uit de initiële opdrachtvorming (het Plan van Aanpak) en zijn vervolgens in direct overleg met de Product Owner en bedrijfsbegeleider definitief als hoogste prioriteit gemarkeerd voor de realisatie van de Proof of Concept (POC). Zonder de realisatie van deze eisen is het op te leveren eindproduct niet functioneel of onbruikbaar.

Should have: Deze toewijzing is in overleg met de Product Owner toegekend aan eisen die een duidelijke functionele meerwaarde bieden en sterk bijdragen aan de acceptatie en transparantie van het systeem, mede gebaseerd op belangrijke gebruikersbehoeften uit de interviews. Hoewel ze essentieel zijn voor een volwaardig eindproduct, is het ontbreken ervan niet direct blokkerend voor de initiële werking van de POC.

Could have: Deze categorie omvat eisen die door individuele respondenten of vanuit de projectgroep zijn aangedragen als waardevolle toevoegingen voor de algehele bruikbaarheid of verdere evaluatiedoeleinden. De realisatie van deze eisen is optioneel en wordt alleen meegenomen als er, na het succesvol afronden van de hogere prioriteiten, nog voldoende ontwikkelcapaciteit en tijd beschikbaar is binnen dit onderzoek.

Won't have (in deze fase): Deze toewijzing is gereserveerd voor eisen die tijdens het onderzoek of de interviews zijn besproken, maar expliciet buiten de scope van de huidige fase en de POC vallen. Redenen voor uitsluiting zijn dat een eis niet aansluit bij de vastgestelde rol en architectuur van het doelsysteem (zoals Ricgraph), of dat noodzakelijke randvoorwaarden ontbreken om de eis te realiseren. Deze punten zijn vastgelegd als input voor eventueel vervolgonderzoek of andere verdere ontwikkeling.

5.2.2 IST-SOLL gap analyse

Binnen de huidige inrichting van Ricgraph worden publicaties geclassificeerd op basis van metadata uit bronsystemen zoals Pure en Yoda. Dit leidt tot een inconsistente dataset wegens ontbrekende of door auteurs subjectief toegewezen keywords. Om dit probleem op te lossen is een proces ingericht dat bestaat uit drie losse scripts. In deze opzet worden OpenAlex topics lokaal gevectoriseerd, worden ontbrekende abstracts via de API opgehaald en worden teksten door middel van cosine similarity (een wiskundige methode om de inhoudelijke overeenkomst tussen twee gevectoriseerde teksten te berekenen) gekoppeld aan topics. Een Large Language Model (LLM) fungeert hierin als een optionele module. Een belangrijk knelpunt binnen de huidige IST-situatie is het ontbreken van een gestandaardiseerde procesinrichting. Er ontbreekt momenteel een geformaliseerde strategie en theoretische onderbouwing voor zowel de selectie van het classificatiemodel als de methodiek waarmee dit model wordt ingezet. Daarnaast is de dataverwerkingsketen onvolledig en ontbreekt een visuele representatie van de uitkomsten.

Het doelsysteem vereist een weloverwogen procesinrichting waarbij een LLM-gebaseerde classificatie als primair mechanisme binnen de standaard workflow functioneert. Dit geautomatiseerde proces moet consistent zijn, schaalbaar tot miljoenen publicaties en alle parameters loggen om reproduceerbaarheid te garanderen. Het systeem moet voor de gebruiker

transparant zijn over de totstandkoming van de topics door het opslaan van versie-informatie en het gebruik van begrijpelijke terminologie.

5.2.2.1 Gap 1: Modelstrategie en Procesinrichting (F1, F4, NF8)

Wat betreft de procesinrichting en modelkeuze bevindt het grootste hiaat zich in het ontbreken van een structurele onderbouwing voor het classificatieproces. Momenteel is niet vastgelegd welk model het meest geschikt is en hoe de abstracts exact door het model moeten worden verwerkt. In de gewenste situatie wordt een specifiek LLM doelbewust geselecteerd en structureel ingericht als de primaire methode voor toewijzing (F1). De benodigde actie is het ontwerpen en documenteren van een gerichte modelstrategie, waarbij de technische inzet en promptconfiguratie vooraf worden vastgesteld.

Bij de procesintegratie is het verschil dat de huidige opzet uit drie losse scripts bestaat. De gewenste situatie stelt dat de classificatie een geïntegreerd onderdeel is van de standaard flow (F4) zonder dat hier handmatige tussenstappen voor vereist zijn (NF8). Het actiepunt is het samenvoegen en automatiseren van de afzonderlijke scripts tot één doorlopende pijplijn.

5.2.2.2 Gap 2: Schaalbaarheid en Performance (NF4, NF5)

Wat betreft schaalbaarheid en snelheid is de huidige lokale bestandsverwerking onvoldoende toegerust voor opschaling. Het doelsysteem stelt als eis de verwerking van minimaal 100.000 publicaties per dag (NF5) en de capaciteit om te schalen naar 3 miljoen publicaties (NF4). Dit vraagt om technische optimalisaties in de architectuur voor een hogere verwerkingssnelheid en efficiënt API-gebruik.

5.2.2.3 Gap 3: Reproduceerbaarheid en Validatie (F2, NF1, NF2)

Voor reproduceerbaarheid en kostenbeheer ontbreekt momenteel de vastlegging van testdata en uitgaven. De eisen stellen dat alle testparameters per run worden gelogd (F2) en API-kosten bewust worden bijgehouden door middel van proefruns (NF2). Hiervoor moet een loggingmechanisme worden geïmplementeerd dat modelparameters zoals temperature, top-k en de prompt registreert, gecombineerd met een module voor de monitoring van het verbruik. Ook vraagt de gewenste situatie dat het systeem consistente resultaten levert: herhaalde runs op dezelfde input moeten aantoonbaar vergelijkbare topics produceren, wat meetbaar moet zijn via een Jaccard index (NF1). Het actiepunt hiernaast is dan ook het inbouwen van een geautomatiseerde validatiestap die de consistentie tussen opeenvolgende classificatieruns kwantitatief meet.

5.2.2.4 Gap 4: Transparantie en Visualisatie (F7, NF6, NF7)

Tot slot is er een hiaat in de zichtbaarheid en de gebruikersinterface. Op dit moment ontbreekt een gestandaardiseerde weergave in de front-end. Het beoogde systeem moet transparantie bieden over hoe en wanneer topics zijn toegekend (F7, NF7) en de interface moet spreektaal gebruiken in plaats van technische termen (NF6). De actie is het ontwikkelen van basisfunctionaliteit binnen de interface om resultaat gericht te kunnen ontwikkelen, en inzicht en transparantie voor de gebruiker te waarborgen.

5.3 Deelvraag 3

Welke LLM-modellen en welke configuraties daarvan sluiten het beste aan bij het topicsproces gegeven de eisen uit de SOLL situatie?

5.3.1 Longlist

Commerciële Cloud-Modellen

Deze modellen dienen vaak als "gold standard" vanwege hun hoge mate van tekstbegrip, maar brengen privacyoverwegingen en variabele kosten met zich mee.

MODEL	AANBIEDER	ONDERBOUWING VOOR RICGRAPH
GPT-5.4 (OPENAI, 2026)	OpenAI	Dient als standaard voor complexe context en redeneervermogen.
GPT-5.4 MINI (OPENAI, 2026)	OpenAI	De mini-variant is een kostenefficiënte optie voor dit project bij het verwerken van grote volumes.
CLAUDE 4.6 SONNET (ANTHROPIC, 2026)	Anthropic	Staat bekend om het nauwkeurig opvolgen van systeem-instructies (system prompts), wat een voordeel is bij het mappen van de output naar de OpenAlex-taxonomie.
CLAUDE HAIKU 4.5 (ANTHROPIC, 2025)	Anthropic	Een kleinere, snellere en meer kostenefficiënte versie van Sonnet.
GEMINI 3.5 FLASH (GOOGLE, 2026)	Google	Geoptimaliseerd voor snelheid en grote volumes. Het ruime contextvenster maakt batchverwerking van abstracts mogelijk voor betere consistentie.
GEMINI 3.1 PRO (GOOGLE, 2026)	Google	Het meest geavanceerde model van Google, gericht op complexe redeneertaken.

Tabel 5 - Longlist commerciële cloud modellen

Open-Source Modellen

Deze modellen kunnen lokaal of binnen de infrastructuur van de universiteit draaien. Dit biedt aanzienlijke voordelen voor databeheer, privacy en beheersbaarheid, omdat de data de eigen systemen niet verlaat.

MODEL	ONTWIKKELAAR	ONDERBOUWING VOOR RICGRAPH
META LLAMA 3 (8B INSTRUCT) (META, 2024)	Meta	In gebruik: Dit model wordt momenteel in het script gebruikt via de llama-cpp integratie. Het dient als de primaire baseline.
LLAMA 3.1 (8B/70B) (META, 2024)	Meta Llama 3 (8B Instruct Meta)	De huidige industriestandaard voor open-source. De 8B-versie is zeer efficiënt, terwijl de 70B-versie qua redeneervermogen concurreert met grotere commerciële modellen.
LLAMA-4-SCOUT-17B-16E-INSTRUCT (META, 2025)	Meta	Nieuwere iteratie met een grotere parameteromvang voor verbeterd tekstbegrip.
MISTRAL NEMO (12B) (MISTRALAI, 2024)	Mistral / NVIDIA	Specifiek ontworpen om op één consumenten-GPU te passen. Biedt een sterke balans tussen rekenkracht en nauwkeurigheid.
DEEPSEEK-R1(685B) (DEEPSEEK-AI, 2025)	Deepseek-AI	Zeer krachtig open-source model, maar vereist zware hardware-infrastructuur.

PHI-3.5-MINI (MICROSOFT, 2024)	Microsoft	Een Small Language Model (SLM) dat sterk is in logische classificatietaken, wat de herhaalbaarheid (consistentie) ten goede komt.
GPT-OSS-120B (OPENAI, 2025)	OpenAI	Zeer groot model (120 miljard parameters) dat direct toegankelijk is via de interne systemen van de universiteit. Combineert hoge redeneerkracht met een zeer hoge implementatiehaalbaarheid en databeveiliging, aangezien het platform en de infrastructuur reeds intern gefaciliteerd zijn.

Tabel 6 - Longlist Open-Source Modellen

Domeinspecifieke & Encoder Modellen

In plaats van generatieve modellen kunnen ook modellen worden ingezet die specifiek zijn getraind op wetenschappelijke taal of optimalisatie van vectorberekeningen.

MODEL	TYPE	ONDERBOUWING VOOR RICGRAPH
ALL-MINILM-L6-V2 (SENTENCE-TRANSFORMERS, 2024)	Sentence-Transformer	In gebruik: Het huidige standaardmodel voor het genereren van tekst-embeddings. Snel en lichtgewicht.
ALL-MPNET-BASE-V2 (SENTENCE-TRANSFORMERS, 2021)	Sentence-Transformer	Overwogen: Wordt in de code genoemd als alternatief. Nauwkeuriger dan de MiniLM, maar vereist meer rekenkracht
SCIBERT (BELTAGY, LO, & COHAN, 2019)	Specialistisch	Specifiek getraind op wetenschappelijke papers. Mogelijk sterker in het begrijpen van domeinspecifieke abstracts dan algemene modellen.
COMPREHEND_IT-BASE (KNOWLEDGATOR, 2024)	Knowledgator	Klein model getraind op <i>zero-shot classification</i> , kan met <i>candidate labels</i> direct OpenAlex-topics toepassen.
DEBERTA-V3 (MICROSOFT, 2021)	NLU Encoder	Sterk presterende encoder voor Natural Language Understanding. Geschikt voor de validatiestap waarbij output wordt gematcht aan OpenAlex-topics.
GALACTICA (TAYLOR, ET AL., 2022)	Wetenschappelijk LLM	Getraind op wetenschappelijke data. Biedt inzicht of een domeinspecifiek getraind model beter presteert op abstracts dan algemene modellen.

Tabel 7 - Longlist Domeinspecifieke & Encoder Modellen

5.3.2 Shortlist

Zoals beschreven in de methodologie, zijn de modellen uit de longlist gefilterd op basis van de harde uitsluitingscriteria uit de SOLL-situatie. Modellen die niet voldeden aan de eisen rondom dataprivacy, onvoldoende schaalbaar bleken, of een onnodig groot en inefficiënt *context window* vereisten voor het verwerken van korte abstracts, zijn geschrapt. Op basis van deze selectie is op de shortlist gekozen voor een combinatie van efficiënte cloud-modellen, intern gehoste open-source modellen en specifieke encoders. Daarnaast is voor de open-source modellen gekozen voor kleinere

en efficiëntere varianten, aangezien de analyse van abstracts slechts een klein contextvenster vereist.

Commerciële Cloud-Modellen

MODEL	AANBIEDER	ONDERBOUWING VOOR RICGRAPH
GPT-5.4 MINI	OpenAI	Kostenefficiënt en snel voor het verwerken van de volledige dataset.
CLAUDE HAIKU 4.5	Anthropic	Goedkopere versie van Sonnet met sterke prompt-opvolging.
GEMINI 3.5 FLASH	Google	Groot contextvenster maakt batchgewijze analyse van abstracts mogelijk.

Tabel 8 - Shortlist Commerciële Cloud-Modellen

Open-Source Modellen

MODEL	ONTWIKKELAAR	ONDERBOUWING VOOR RICGRAPH
META LLAMA 3 (8B INSTRUCT)	Meta	In gebruik: Dient als de primaire baseline voor de LLM-generatiefase.
LLAMA-4-SCOUT-17B-16E-INSTRUCT	Meta	Nieuwere versie met een grotere parameteromvang.
GPT-OSS-120B	OpenAI	Biedt de rekenkracht van een zwaar model (120B), maar is zonder technische barrières of externe datadeling direct inzetbaar via de interne universitaire infrastructuur.

Tabel 9 - Shortlist Open-Source Modellen

Domeinspecifieke & Encoder Modellen

MODEL	TYPE	ONDERBOUWING VOOR RICGRAPH
ALL-MINILM-L6-V2	Sentence-Transformer	In gebruik: De huidige snelle, lichtgewicht baseline voor vectorisatie.
SCIBERT	Specialistisch	Biedt wetenschappelijke context die generieke modellen mogelijk missen.

Tabel 10 - Shortlist Domeinspecifieke & Encoder Modellen

5.3.3 SFA model

Definities SFA-criteria

Om een objectieve en gestructureerde modelkeuze te faciliteren, wordt het Suitability, Feasibility en Acceptability (SFA) model toegepast. In de onderstaande tabel zijn de beoordelingscriteria voor dit onderzoek gedefinieerd en direct gekoppeld aan de eerder vastgestelde functionele en niet-functionele eisen. De categorie 'Suitability' toetst de functionele geschiktheid van een model, zoals het vereiste redeneervermogen en de verwerkingssnelheid. 'Feasibility' beoordeelt de technische en financiële kaders, waaronder de infrastructuur en benodigde expertise. Tot slot weegt 'Acceptability' de organisatorische randvoorwaarden, met een specifieke focus op licentievormen, beheersbaarheid en dataprivacy. Deze afbakening vormt het meetbare vertrekpunt voor de uiteindelijke analyse.

SFA	INVALSHOEK	INVULLING	BRON
-----	------------	-----------	------

SUITABILITY	Redenering	Kan het model op basis van een abstract zelfstandig topics toewijzen binnen een gesloten vocabulaire?	F1, F3
SUITABILITY	Domeinspecifieke context	Heeft het model voldoende wetenschappelijke domeinkennis voor accurate toewijzing aan OpenAlex-topics?	F1, F3
SUITABILITY	Context window	Is het context window groot genoeg voor abstract + prompt + vocabulaire-instructies?	F1, F3
SUITABILITY	Snelheid	Kan het model minimaal 100.000 publicaties per dag verwerken?	NF5
FEASIBILITY	Kosten	API- of rekenkosten zijn beheersbaar en vooraf inschatbaar via proefrun	NF2
FEASIBILITY	Technische infrastructuur	Lokaal of via API inzetbaar; loggable run-parameters; aansluitend op harvest-flow	F2, F4
FEASIBILITY	Benodigde expertise	Complexiteit van implementatie en configuratie binnen het projectteam	—
FEASIBILITY	Schaalbaarheid	Schaalbaar naar 3M publicaties zonder architectuurwijziging	NF4
ACCEPTABILITY	Licentie/openheid	Open-source of proprietary; impact op herbruikbaarheid, aanpasbaarheid en vendor lock-in, ook wordt of voor deze optie binnen ITS al een licentie/toegang tot is meegenomen	—
ACCEPTABILITY	Beheersbaarheid	Beschikbaarheid van updates, onderhoud en continuïteit op langere termijn	—
ACCEPTABILITY	Stakeholdervertrouwen	Mate waarin het model en de uitkomsten acceptabel zijn voor PO en eindgebruikers	NF3

Tabel 11 - Definities SFA-model

SFA model

Op basis van de gedefinieerde criteria zijn de modellen uit de shortlist in de onderstaande SFA-matrix kwantitatief tegen elkaar afgezet. Om de prioriteiten van het doelsysteem correct te weerspiegelen, is aan elke invalshoek een specifieke weging toegekend. Deze wegingen zijn direct afgeleid van de MoSCoW-prioritering uit de SOLL-situatie. Criteria die gekoppeld zijn aan 'Must have'-eisen, zoals het vereiste redeneervermogen en databeveiliging binnen de technische infrastructuur, kregen hierbij de hoogste weging. Criteria die voortkomen uit 'Should'- of 'Could have's' wogen minder zwaar mee in de einduitslag.

Elk model is vervolgens per subcategorie gescoord op een relatieve schaal van 1 (zeer zwak) tot 10 (zeer sterk). Deze scores zijn systematisch toegekend op basis van de harde specificaties uit de verzamelde modeldocumentatie (zoals de exacte grootte van het context window, verwerkingssnelheden en licentievormen) en de prestatie-indicatoren uit de bestudeerde literatuur. Door de scores te vermenigvuldigen met de wegingen, resulteert de matrix in een gewogen gemiddelde. Dit overzicht biedt de feitelijke onderbouwing voor de definitieve selectie van het model voor de Proof of Concept.

SFA	Invalshoek	Weging	GPT-5.4 mini	Claude Haiku 4.5	Gemini 3.5 Flash	Meta Llama 3 (8B Instruct)	Llama-4-Scout-17B-16E-Instruct	Gpt-oss-120b	all-MiniLM-L6-v2	SciBERT
Suitability	Redenering	5	9	8	10	3	4	7	1	2
	Domeinspecifieke context	2	6	6	7	4	5	7	2	10
	Context window	1	9	8	10	4	7	8	2	3
	Snelheid	3	8	9	10	7	5	4	10	8
Feasibility	Kosten	2	8	8	7	5	3	10	10	10
	Technische Infrastructuur	3	9	9	9	10	3	10	10	8
	Benodigde expertise	2	9	9	9	9	4	8	9	4
	Schaalbaarheid	2	9	9	9	8	5	8	10	8
Acceptability	Licentie/openheid	2	9	3	3	10	8	10	10	10
	Beheersbaarheid	2	5	5	5	10	10	10	10	10
	Stakeholdervertrouwen	2	3	5	4	7	8	9	10	10
	Totaal		203	192	205	176	137	209	189	185
	Gewogen gemiddelde		7,81	7,38	7,88	6,77	5,27	8,04	7,27	7,12

Tabel 12 - SFA-model

5.3.4 Definitieve modelkeuze voor de Proof of Concept

Op basis van de resultaten uit de SFA-matrix en na overleg met de begeleider is een definitieve selectie gemaakt voor de inrichting van de Proof of Concept (PoC). Hoewel commerciële cloud-modellen hoog scoren op verwerkingssnelheid en contextgrootte, is op basis van de hoogste gewogen eindscore in de SFA-analyse besloten om het intern gehoste gpt-oss-120b als nieuw model te integreren en te testen. Dit model biedt de vereiste redeneerkracht voor complexe tekstclassificatie, terwijl het tegelijkertijd de harde projecteisen rondom dataprivacy en kostenbeheersing waarborgt doordat de data de interne infrastructuur niet verlaat.

Om de prestaties van dit nieuwe model objectief te kunnen meten en valideren, wordt de PoC zo ingericht dat gpt-oss-120b vergeleken kan worden met twee reeds lokaal geïmplementeerde baselines:

1. **Meta Llama 3 (8B Instruct):** Dit model blijft behouden als de efficiënte, lichtgewicht open-source baseline voor de LLM-generatiefase. Het fungeert als direct vergelijkingsmateriaal voor de outputkwaliteit en verwerkingssnelheid ten opzichte van het veel zwaardere gpt-oss-120b model.
2. **all-MiniLM-L6-v2:** Voor de vectorisatie (het genereren van embeddings) van de abstracts en OpenAlex-topics blijft dit *Sentence-Transformer* model de standaard. De inzet van dit model is reeds functioneel bewezen binnen de huidige scripts en biedt een snelle, betrouwbare basis voor de wiskundige afhandeling van de tekstvergelijkingen (cosine similarity).

Door deze driedelige configuratie in de architectuur op te nemen, ontstaat een robuuste testomgeving. Het stelt het onderzoek in staat om de accuraatheid, systeembelasting en consistentie van de topic-toewijzing binnen de gewenste doelsituatie meetbaar en reproduceerbaar te evalueren.

5.4 Deelvraag 4

Wat is de best presterende combinatie van LLM-model en configuratie wanneer de selectie uit deelvraag 3 objectief wordt getoetst in een Proof of Concept?

5.4.1 Testresultaten repeatability

Volgens het testplan (zie Bijlage 4: Testplan: Evaluatie LLM-classificatie) zijn de drie geselecteerde backends (all-MiniLM-L6-v2, Meta Llama 3 8B Instruct en gpt-oss-120b) elk in drie configuratiescenario's getest op 924 abstracts, met 5 runs per abstract per configuratie. Onderstaande tabel geeft de gemiddelde verwerkingstijd, het aantal opgetreden fouten en de gemiddelde intra-model Jaccard-score per model en scenario weer.

Testnr	Model	Temp	Prompting	Gemiddelde tijdsduur (in seconden) per run	Errors	avg jaccard
1	mini-lm			144,38	0	1
1	Llama	0.2	standaard	1311,87	0	0,6375
1	Gpt-oss	0.2	std	11520,72	37	0,7578
2	mini-lm			128,08	0	1
2	Llama	0.1	std	1348,01	0	0,7296
2	Gpt-oss	0.1	std	3326,88	10	0,7873
3	mini-lm			111,50	0	1
3	Llama	0.1	std	1387,46	0	0,7296
3	Gpt-oss	0.1	met system en user rollen	4314,60	27	0,7738

Tabel 13 - Testresultaten repeatability per model en configuratiescenario

De embedding-only baseline (mini-lm) behaalt in alle drie de scenario's een Jaccard-score van 1,00 en levert geen enkele fout op. Dit resultaat is een gevolg van het deterministische karakter van het embeddingproces en zegt daarmee niets over de inhoudelijke classificatiekwaliteit ten opzichte van de generatieve modellen, maar bevestigt wel dat mini-lm als stabiele referentiewaarde voor de repeatability-vergelijking kan dienen. Daarnaast is mini-lm met gemiddeld 111 tot 144 seconden per run ruim sneller dan beide LLM-backends.

Llama 3 vertoont over de drie scenario's een stabiele repeatability (0,64 tot 0,73) en een constante verwerkingstijd van circa 1.300 tot 1.390 seconden per run, zonder dat in enig scenario fouten zijn opgetreden. De Jaccard-score van Llama 3 blijft in alle scenario's echter lager dan die van gpt-oss.

Gpt-oss-120b behaalt in elk scenario de hoogste repeatability-score van de drie generatieve modellen, maar gaat gepaard met een aanzienlijk hogere verwerkingstijd en foutgevoeligheid. Het aantal fouten daalt sterk van 37 in scenario 1 (temperature 0.2) naar 10 in scenario 2 (temperature 0.1), wat erop wijst dat een lagere temperature-instelling leidt tot stabielere en beter afgeronde output van het model. In scenario 3, waarin naast dezelfde lage temperature ook de prompt is opgesplitst in een system- en user-rol, ligt het aantal fouten met 27 echter weer beduidend hoger dan in scenario 2, en blijft ook de Jaccard-score (0,7738) lager dan in scenario 2 (0,7873). Dit duidt

erop dat de temperatuurverlaging de grootste bijdrage levert aan de verbetering tussen scenario 1 en 2, terwijl de aanvullende structurering van de prompt in scenario 3 geen aantoonbaar positief effect oplevert ten opzichte van de standaardprompting bij dezelfde temperature-instelling.

5.4.2 Inter-model vergelijking

Zoals toegelicht in de methodologie is, naast de reproduceerbaarheidsmeting, een aanvullende vergelijking uitgevoerd tussen de modellen onderling. Hierbij is per modelkoppel de gemiddelde Jaccard-index over 5 runs berekend, om te onderzoeken of en in welke mate de modelkeuze inhoudelijk invloed heeft op de toegewezen topics.

Testnr	Model 1	model 2	Gemiddelde Jaccard index over 5 runs
1	mini-lm	Gpt-oss	0,553
1	mini-lm	Llama	0,4462
1	Gpt-oss	Llama	0,4331
2	mini-lm	Gpt-oss	0,5549
2	mini-lm	Llama	0,4464
2	Gpt-oss	Llama	0,4321
3	mini-lm	Gpt-oss	0,5594
3	mini-lm	Llama	0,4461
3	Gpt-oss	Llama	0,4345

Tabel 14 - Gemiddelde inter-model Jaccard-index per modelkoppel en configuratiescenario

De inter-model Jaccard-scores liggen in alle drie de scenario's tussen 0,43 en 0,56, aanzienlijk lager dan de intra-model repeatability-scores uit paragraaf 4.7.1. Dit verschil houdt in dat de modellen, ondanks een acceptabele interne stabiliteit, structureel andere topicsets aan dezelfde abstracts toekennen. mini-lm vertoont in alle scenario's een hogere overeenkomst met gpt-oss (0,55 tot 0,56) dan met Llama 3 (0,45), terwijl de overeenkomst tussen gpt-oss en Llama 3 onderling het laagst is (0,43 tot 0,43). Dit resultaat wijst erop dat de keuze tussen Llama 3 en gpt-oss niet vrijblijvend is: de twee modellen selecteren voor eenzelfde abstract merendeels verschillende topics, wat een directe implicatie heeft voor de uiteindelijke inhoudelijke uitkomst van het classificatieproces binnen Ricgraph.

5.4.3 Samenvatting modelprestaties

Uit de repeatability-resultaten en de inter-model vergelijking blijkt dat gpt-oss in alle scenario's de hoogste Jaccard-score behaalt (tot 0,7873 in test 2). Dit model noteert tevens de langste verwerkingstijd en het hoogste aantal fouten. Het aantal fouten bij gpt-oss daalt van 37 bij een temperatuur van 0.2, naar 10 bij een temperatuur van 0.1. Llama 3 toont een stabielere verwerkingstijd en kent in geen van de scenario's fouten, maar behaalt structureel lagere Jaccard-scores (maximaal 0,7296) dan gpt-oss.

Wat betreft de inter-model vergelijking ligt de Jaccard-index structureel lager (0,43 tot 0,56) dan de intra-model repeatability-scores. Daarbij laat de data zien dat mini-lm in alle scenario's een grotere overlap vertoont met de output van gpt-oss (0,55 - 0,56) dan met de output van Llama 3 (0,44 - 0,45). De overlap tussen gpt-oss en Llama 3 is onderling het laagst (0,43).

5.4.4 Realisatie van de Proof of Concept (POC) en UI-koppeling

Naast de statistische evaluatie van de modellen heeft dit onderzoek geresulteerd in een werkende Proof of Concept. De POC is technisch gerealiseerd als een geïntegreerde datapijplijn binnen de testomgeving van Ricgraph. De geselecteerde modellen zijn via Python-scripts gekoppeld aan het

classificatieproces. In dit proces fungeren de abstracts van publicaties als invoer, waarna het geselecteerde model de best passende OpenAlex-topics toewijst. Deze verrijkte data schrijft vervolgens succesvol weg naar de Neo4j-graafdatabase (eis F1, F4). Tijdens de uitvoering van de POC zijn alle systeemp parameters, zoals temperatuur en modelversie, gelogd om de reproduceerbaarheid te waarborgen (eis F2).

Om de gegenereerde data inzichtelijk te maken, is een interface-uitbreiding ontwikkeld voor de Ricgraph Explorer. Er is een nieuwe zoekfunctionaliteit geïmplementeerd waarmee de toegewezen topics verkend kunnen worden.

Binnen deze UI-koppeling zijn de volgende functionaliteiten gerealiseerd:

Selectie en filtering: Gebruikers kunnen maximaal tien topics selecteren uit een gestructureerde lijst

Logische AND-relatie: Wanneer meerdere topics worden geselecteerd, filtert het systeem de resultaten op basis van een AND-operator. Dit betekent dat uitsluitend de overlap (de publicaties die aan álle geselecteerde topics zijn gekoppeld) wordt getoond. (Zie Figuur 6 - Invoerscherm topic-zoekfunctionaliteit)

Dataweergave: De interface toont de resulterende lijst van publicaties (DOI's) en de daaraan verbonden auteurs (person root nodes), waardoor de netwerkrelaties rondom een specifiek onderzoeksgebied visueel inzichtelijk worden. (Zie Figuur 7 - Weergave van de resulterende publicaties en auteurs)

Go back Ricgraph Explorer Home Broad search Advanced search REST API doc

Topics

Select up to 10 topics

This page allows you to select topics harvested into Ricgraph. Ricgraph Explorer will show all DOI research results that match *all* selected topics.

Type to search for more topics in the list below:

- ☐ 14-3-3 protein interactions
- ☐ 21st Century Education and Governance
- ☐ 2D Materials and Applications
- ☐ 3D Printing In Biomedical Research
- ☐ 3D Shape Modeling and Analysis
- ☐ Abdominal Trauma and Injuries
- ☐ Academic Research and Education Studies
- ☐ Access Control and Trust
- ☐ Accounting Theory and Financial Reporting
- ☐ Acoustic Wave Phenomena Research

Search

Figuur 6 - Invoerscherm topic-zoekfunctionaliteit

6 Conclusie

Dit onderzoek richtte zich op de beantwoording van de volgende hoofdvraag: Welke LLM-gebaseerde aanpak voor topicgeneratie presteert het beste voor de classificatie van publicaties binnen Ricgraph, en hoe kan deze worden geïntegreerd in de Ricgraph-keten en gebruikersinterface?

Uit de analyse van de huidige situatie bleek dat de classificatie van publicaties binnen Ricgraph bestond uit gefragmenteerde, lokale scripts zonder formele modelstrategie en zonder weergave in de gebruikersinterface. Op basis van de opgestelde systeemeisen werd vastgesteld dat een nieuwe aanpak moest resulteren in een reproduceerbaar proces waarbij de toegewezen topics (gebruikmakend van het OpenAlex-vocabulaire) via een doorlopende datapijplijn inzichtelijk en filterbaar worden in de Explorer. Gestuurd door deze eisen en het SFA-model, werd gekozen voor een testopstelling met gpt-oss-120b als primair redeneermodel, Meta Llama 3 (8B) als efficiënte baseline, en all-MiniLM-L6-v2 voor de vectorisatie.

De resultaten uit het Proof of Concept tonen aan dat het integratievraagstuk succesvol is opgelost: de losse scripts zijn geautomatiseerd samengevoegd tot één keten. Bovendien is er een functionerende interface-uitbreiding gerealiseerd waarin gebruikers met logische AND-relaties kunnen filteren op de toegewezen topics om bijbehorende publicaties en auteurs te identificeren. Uit de evaluatie van de modellen blijkt dat gpt-oss-120b bij een verlaagde temperatuur van 0.1 de hoogste reproduceerbaarheid behaalt, gemeten via een gemiddelde Jaccard-index van 0,7873 over herhaalde runs.

Concluderend is de configuratie van het gpt-oss-120b model met een temperatuur van 0.1 de best presterende aanpak voor topicgeneratie, aangezien deze de hoogste stabiliteit en consistentie levert voor het doelsysteem. Deze AI-aanpak is via een Proof of Concept succesvol, meetbaar en functioneel geïntegreerd in de Ricgraph-keten en de bijbehorende gebruikersinterface.

7 Discussie

De validiteit en betrouwbaarheid van dit onderzoek zijn gewaarborgd door het hanteren van een gestandaardiseerde, kwantitatieve testomgeving op basis van het CoLLM-raamwerk. Door een representatieve dataset van 924 unieke publicaties te gebruiken en elk model vijf afzonderlijke keren op exact dezelfde input te laten draaien, is de invloed van toevalsfactoren geminimaliseerd. De toepassing van paarsgewijze Jaccard-vergelijkingen zorgt voor een robuuste, statistisch verantwoorde meting van de reproduceerbaarheid. Alle gemaakte keuzes, prompt-configuraties en hyperparameters zijn systematisch vastgelegd, wat de reproduceerbaarheid van het onderzoek zelf garandeert.

De resultaten komen grotendeels overeen met de initiële verwachting dat Large Language Models, ondanks hun probabilistische karakter, via gecontroleerde parameters inzetbaar zijn voor deterministische taken. Het verlagen van de temperatuur leidde zoals voorspeld tot een stabielere output. Opvallend was de uitkomst van de inter-model vergelijking. De verwachting was dat modellen kleine, willekeurige variaties zouden vertonen rondom eenzelfde betekenis. De consistent lage inter-model Jaccard-index (0,43) toont echter aan dat gpt-oss-120b en Meta Llama 3 structureel andere topics selecteren voor dezelfde tekst. De keuze voor een model bepaalt dus sterk het inhoudelijke profiel van de geclassificeerde data.

Uit de resultaten bleek dat het gpt-oss-120b model de hoogste Jaccard-score behaalde, maar gelijktijdig de langste verwerkingstijd en de hoogste foutgevoeligheid kende ten opzichte van de baseline. Een verklaring voor de stabiliteitswinst (de daling van het aantal fouten van 37 naar 10) is de aanpassing van de temperatuurparameter van 0.2 naar 0.1, wat de creativiteit van het model beperkt en vroegtijdige afbreking van gegenereerde tekst voorkomt.

De resterende foutgevoeligheid bij gpt-oss-120b is waarschijnlijk terug te voeren op de technische infrastructuur. De SURF-omgeving waarop dit zware model lokaal werd gehost, bevond zich tijdens het onderzoek nog in een bèta-fase. Het is de verwachting dat met de verdere doorontwikkeling van deze omgeving en het topics proces de geregistreerde netwerk- of capaciteitsfouten zullen afnemen.

Daarnaast vormt de aanzienlijk langere verwerkingstijd van dit model in de praktijk geen zwaarwegende beperking voor het doelsysteem. Het classificatieproces is dusdanig ingericht dat elke wetenschappelijke publicatie slechts eenmalig geclassificeerd hoeft te worden nadat deze door Ricgraph is geharvest. Een hogere initiële runtime weegt hierdoor minder zwaar dan het kwalitatieve belang van een consistente toewijzing voor de eindgebruiker.

7.1 Beperkingen

Een fundamentele beperking van dit onderzoek is het ontbreken van een absolute ground truth. Het onderzoek heeft uitsluitend de interne consistentie (reproduceerbaarheid) van de classificatie gemeten. Dit geeft geen garantie over de inhoudelijke accuraatheid. Een model kan zeer consistent de verkeerde of niet-intuïtieve topics toewijzen.

Zoals uit de gebruikersinterviews naar voren kwam, ervaren domeinexperts de gestandaardiseerde OpenAlex-labels soms als te rigide of niet passend bij hun vakjargon. Doordat de LLM-output nu dwingend wordt omgezet naar deze specifieke thesaurus, ontstaat een afhankelijkheid van de kwaliteit van OpenAlex, onafhankelijk van het redeneervermogen van het geselecteerde LLM. Tot slot is de classificatie uitsluitend getest op Engelstalige abstracts. Alhoewel dit het overgrote deel van de dataset dekt, is de betrouwbaarheid van het model op anderstalige teksten onbewezen.

7.2 Aanbevelingen voor vervolgonderzoek

Naar aanleiding van de resultaten en de geïdentificeerde beperkingen, worden de volgende concrete vervolgonderzoeken aangeraden:

Inhoudelijke validatie door domeinexperts: Een kwalitatief vervolgonderzoek waarbij wetenschappelijke onderzoekers en dataspecialisten de door de LLM toegewezen topics handmatig evalueren op semantische juistheid, om de daadwerkelijke accuraatheid van de geselecteerde methode vast te stellen. Hiermee kan de missende ground truth worden vastgesteld en beter onderzocht worden hoe waardevol de rol van een LLM is binnen dit classificatieproces.

Onderzoek naar hybride weergave: Een analyse naar de gebruikersacceptatie wanneer de ongestructureerde, ruwe output (de directe LLM-keywords) in de Explorer zij-aan-zij wordt gepresenteerd met de gestandaardiseerde OpenAlex-topics, om beter aan te sluiten bij het referentiekader van de onderzoeker.

Fine-tuning van de modelconfiguratie: Vanwege tijdsbeperkingen is binnen dit onderzoek slechts in beperkte mate geëxperimenteerd met de configuratie van de verschillende modellen. Er is echter nog veel potentiële winst te behalen om de nauwkeurigheid en efficiëntie van het geïmplementeerde model te optimaliseren. Aanvullend onderzoek naar de invloed van andere hyperparameters en geavanceerdere prompting-strategieën wordt daarom sterk aanbevolen.

8 Aanbevelingen

Op basis van de resultaten, de conclusie en de opgedane inzichten tijdens de realisatie van de Proof of Concept (POC), zijn vier aanbevelingen geformuleerd. Deze aanbevelingen zijn gericht aan de Product Owner en het ontwikkelteam van Ricgraph. Ze focussen op het optimaliseren van de modelprestaties, het verhogen van de verwerkingssnelheid en het verbeteren van de gebruikerservaring in de Explorer. De aanbevelingen zijn gerangschikt op verwachte impact en technische haalbaarheid.

8.1 Directe toewijzing van OpenAlex-topics door het LLM:

Binnen de huidige POC is het proces in twee stappen opgedeeld: het LLM genereert eerst vrij geformuleerde topics, waarna deze via cosine similarity worden gematcht aan de officiële OpenAlex-thesaurus. Het wordt aanbevolen om te onderzoeken of het LLM de OpenAlex-topics direct kan genereren.

Onderbouwing: De huidige tussenstap introduceert een risico op semantisch verlies wanneer de gegenereerde term wiskundig aan een nèt iets ander OpenAlex-topic wordt gekoppeld.

Bijdrage en haalbaarheid: Door de relevante context van de OpenAlex-thesaurus direct in de *system prompt* te verwerken, kan het model gedwongen worden uitsluitend gevalideerde topics als output te leveren. Dit verhoogt de accuraatheid, elimineert de noodzaak voor een extra vector-berekening en is technisch realiseerbaar door prompt-engineering toe te passen op een model met een voldoende groot contextvenster.

8.2 Dynamische resultaatfiltering in de Ricgraph Explorer

Voor de ontwikkelde gebruikersinterface wordt aanbevolen om een dynamisch filtermechanisme te implementeren bij het selecteren van topics.

Onderbouwing: In de huidige interface blijft de volledige lijst met duizenden topics zichtbaar nadat een eerste topic is geselecteerd. Omdat er een AND-relatie geldt, leidt het selecteren van een tweede topic dat geen overlap heeft met het eerste topic tot een leeg zoekresultaat.

Bijdrage en haalbaarheid: Wanneer het systeem de overgebleven topic-lijst dynamisch filtert en uitsluitend de topics toont die daadwerkelijk een overlap hebben met de reeds gemaakte selectie, wordt voorkomen dat gebruikers vastlopen in zoekopdrachten zonder resultaat. Dit is een gebruikersgerichte toevoeging die met behulp van de bestaande graafstructuur (waarin alle relaties al bekend zijn) qua ontwikkeltijd te overzien is.

8.3 Implementatie van batchverwerking ter prestatieverbetering

Om de verwerkingstijd van het topicproces zo schaalbaar mogelijk te maken, wordt aangeraden om over te stappen op asynchrone batchverwerking voor de grote (met name initiële) API-aanroepen.

Onderbouwing: Uit de prestatiemetingen bleek dat het proces vertraging oploopt door *rate limiting* mechanismen (beleefdheidsvertragingen) van externe API's of modellen. Bij een sequentiële verwerking waarbij per abstract wordt gewacht op een antwoord, stijgt de totale verwerkingstijd exponentieel naarmate de dataset groeit.

Bijdrage en haalbaarheid: Door de abstracts te groeperen (batching) en asynchroon naar het LLM te sturen, kan de doorvoersnelheid drastisch worden verhoogd en wordt de impact van individuele API-vertragingen geminimaliseerd. Deze optimalisatie vereist beperkte aanpassingen in de bestaande Python-architectuur en kan grote voordelen opleveren. Voornamelijk bij de initiële classificatie van

de al bestaande publicaties binnen de database waarbij in één keer heel veel gevraagd wordt van de API.

8.4 Verbreding en kwaliteitscontrole van de invoerdata

Het huidige model baseert de classificatie uitsluitend op de ruwe abstract van een publicatie.

Aanbevolen wordt om ook de publicatietitel mee te sturen naar het LLM en een kwaliteitscontrole in te bouwen op de aangeleverde abstracts.

Onderbouwing: Niet elke geharveste abstract is van voldoende kwaliteit of lengte om een accurate classificatie op te baseren. Soms is de abstract te beknopt of ontbreekt specifieke terminologie die wel in de titel staat.

Bijdrage en haalbaarheid: Het combineren van titel en abstract vergroot de semantische context voor het model, wat resulteert in nauwkeurigere topic-toewijzingen. Daarnaast voorkomt een eenvoudige script-validatie (bijvoorbeeld een minimum aantal woorden) dat het LLM onnodig tokens verbruikt aan teksten die te kort zijn voor een zinvolle analyse. Beide toevoegingen maken gebruik van data die al in de Ricgraph-database aanwezig is en vereisen minimale implementatietijd.

Literatuurlijst/Bibliografie

- Anthropic. (2025, Oktober 15). *Introducing Claude Haiku 4.5*. Opgehaald van anthropic: <https://www.anthropic.com/news/claude-haiku-4-5>
- Anthropic. (2026, februari 17). *Introducing Claude Sonnet 4.6*. Opgehaald van anthropic: <https://www.anthropic.com/news/claude-sonnet-4-6>
- Arora, C., Sayeed, A. I., Licorish, S., Wang, F., & Treude, C. (2024). Optimizing Large Language Model Hyperparameters for Code Generation. *Arxiv*.
- Beltagy, I., Lo, K., & Cohan, A. (2019). SciBERT: A Pretrained Language Model for Scientific Text. *The 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)* (pp. 3615–3620). Hong Kong, China: Association for Computational Linguistics.
- Bullers, K., Howard, A. M., Hanson, A., Kearns, W. D., Orriola, J. J., Polo, R. L., & Sakmar, K. A. (2018). It takes longer than you think: librarian time spent on systematic review tasks. *Journal of the Medical Library Association : JMLA*, 106(2), 198–207.
- De Castro, P., & Hanna-Mari, P. (2023). Research Information Management Systems: covering the whole research lifecycle. *EUNIS 2023 Annual Conference*. Vigo: EUNIS.
- de Castro, P., Shearer, K., & Summann, F. (2014). The Gradual Merging of Repository and CRIS Solutions to Meet Institutional Research Information Management Requirements. *Procedia Computer Science volume 33*, 39-46.
- DeepSeek-AI. (2025). DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. *Nature, Volume 645, Issue 8081*, 633-638.
- euroCris. (2012, Oktober 17). *Common European Research Information Format*. Opgehaald van Interoperable Europe: <https://interoperable-europe.ec.europa.eu/collection/eu-semantic-interoperability-catalogue/solution/common-european-research-information-format>
- euroCRIS. (2024). *What is euroCRIS*. Opgehaald van eurocris.org: <https://eurocris.org/what-eurocris>
- Fensel, D., Şimşek, U., Angele, K., Huaman, E., Kärle, E., Panasiuk, O., . . . Wahler, A. (2020). *Knowledge Graphs*. Springer.
- Google. (2026, Februari). *Gemini 3.1 Pro Preview*. Opgehaald van ai.google.dev: <https://ai.google.dev/gemini-api/docs/models/gemini-3.1-pro-preview>
- Google. (2026, Mei). *Gemini 3.5 Flash*. Opgehaald van ai.google.dev: <https://ai.google.dev/gemini-api/docs/models/gemini-3.5-flash>
- Gundersen, O. E., & Kjensmo, S. (2018). State of the Art: Reproducibility. *The Thirty-Second AAAI Conference on Artificial Intelligence (AAAI-18)*. AAAI Press.
- Hijmans, E., & Kuyper, M. (2007). Het half open interview als onderzoeksmethode. In P. L. Lucassen, & T. ColdeHartman, *Kwalitatief onderzoek*. Radboud University.
- Janse, B. (2026, January 4). *SFA Matrix: Basics and Template (Johnson and Scholes)*. Opgehaald van Toolshero: <https://www.toolshero.com/marketing/sfa-matrix/>

- Janssen, R. D. (2025). *What is Ricgraph?* Opgehaald van Ricgraph.eu: <https://ricgraph.eu/what-is-ricgraph.html>
- Knowledgator. (2024). *knowledgator/comprehend_it-base*. Opgehaald van Hugging Face: https://huggingface.co/knowledgator/comprehend_it-base
- Lucidchart. (2026). *What is a Data Flow Diagram*. Opgehaald van Lucidchart: <https://www.lucidchart.com/pages/data-flow-diagram>
- Lucidchart. (2026). *What is gap analysis? 4 steps and examples to use*. Opgehaald van Lucidchart: <https://www.lucidchart.com/blog/what-is-gap-analysis>
- Meta. (2024, Juli 23). *meta-llama/Llama-3.1-70B-Instruct*. Opgehaald van Hugging face: <https://huggingface.co/meta-llama/Llama-3.1-70B-Instruct>
- Meta. (2024). *meta-llama/Meta-Llama-3-8B-Instruct*. Opgehaald van Hugging Face: <https://huggingface.co/meta-llama/Meta-Llama-3-8B-Instruct>
- Meta. (2025, April 5). *meta-llama/Llama-4-Scout-17B-16E-Instruct*. Opgehaald van Hugging face: <https://huggingface.co/meta-llama/Llama-4-Scout-17B-16E-Instruct>
- Microsoft. (2021). DEBERTA: DECODING-ENHANCED BERT WITH DISENTANGLED ATTENTION. *International Conference on Learning Representations*. Opgehaald van Hugging Face.
- Microsoft. (2024, Augustus). *microsoft/Phi-3.5-mini-instruct*. Opgehaald van Hugging Face: <https://huggingface.co/microsoft/Phi-3.5-mini-instruct>
- Minaee, S., Mikolov, T., Nikzad, N., Chenaghlu, M., Socher, R., Amatriain, X., & Gao, J. (2025). *Large Language Models: A Survey*. Arxiv.
- Mistralai. (2024). *Model Card for Mistral-Nemo-Base-2407*. Opgehaald van Hugging Face: <https://huggingface.co/mistralai/Mistral-Nemo-Base-2407>
- Mohammed, A., & Kora, R. (2025). A Comprehensive Overview and Analysis of Large Language Models: Trends and Challenges. *IEEE Access*, 95851-95875.
- National Academies of Sciences, E. a. (2019). *Reproducibility and Replicability in Science*. Washington, DC: The National Academies Press.
- Nature. (2009). Credit where credit is due. *Nature Vol 462 Issue no. 7275*, 825.
- Niwattanakul, S., Singthongchai, J., Naenudorn, E., & Wanapu, S. (2013). Using of Jaccard Coefficient for Keywords Similarity. *Proceedings of the International MultiConference of Engineers and Computer Scientists 2013 Vol I*, (pp. 380-384). Hong Kong.
- OpenAI. (2025). *openai/gpt-oss-120B*. Opgehaald van Hugging Face: <https://huggingface.co/openai/gpt-oss-120b>
- OpenAI. (2026, Maart 5). *GPT-5.4*. Opgehaald van developers.openai: <https://developers.openai.com/api/docs/models/gpt-5.4>
- OpenAi. (2026, Maart 5). *GPT-5.4 mini*. Opgehaald van developers.openai: <https://developers.openai.com/api/docs/models/gpt-5.4-mini>
- OpenAlex. (2026). *Topics Overview*. Opgehaald van developers openalex: <https://developers.openalex.org/api-reference/topics>

- ORCID. (sd). *About ORCID*. Opgehaald van ORCID: <https://info.orcid.org/what-is-orcid/>
- Patil, R., & Gudivada, V. (2024). *A Review of Current Trends, Techniques, and Challenges*. Basel: MDPI.
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Arxiv*.
- Russell, S. J., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach, Global Edition 4e*. Englewood Cliffs: Prentice Hall.
- Saeedizade, M. J., Alharbi, R., Babaei Giglou, H., Lippolis, A. S., Blomqvist, E., Tamma, V., . . . Valeyil, Z. (2025). A Framework for Assessing LLM Consistency in Knowledge Engineering. *Semantic Web journal (by IOS Press)*.
- Sarwar, B. K. (2001). Item-based collaborative filtering recommendation algorithms. *Proceedings of the 10th international conference on World Wide Web*, (pp. 285-295).
- Schöpfel, J., Prost, H., & Rebouillat, V. (2017). Research Data in Current Research Information Systems. *Procedia Computer Science Volume 106*, 305-320.
- Sentence-transformers. (2021). *sentence-transformers/all-mpnet-base-v2*. Opgehaald van Hugging Face: <https://huggingface.co/sentence-transformers/all-mpnet-base-v2>
- Sentence-transformers. (2024). *Sentence-transformers/all-MiniLM-L6-v2*. Opgehaald van Hugging Face: <https://huggingface.co/sentence-transformers/all-MiniLM-L6-v2>
- Shyr, C., Ren, B., Hsu, C.-Y., Tinker, R. J., Cassini, T. A., Hamid, R., . . . Xu, H. (2025). A statistical framework for evaluating the repeatability and reproducibility of large language models. *MedRxiv*.
- Srivastava, A., Bhardwaj, S., & Saraswat, S. (2017). SCRUM model for agile methodology. *2017 International Conference on Computing, Communication and Automation (ICCCA)* (pp. 864-869). Greater Noida, India: IEEE.
- Taylor, R., Kardas, M., Cucurull, G., Scialom, T., Hartshorn, A., Saravia, E., . . . Stojnic, R. (2022). GALACTICA: A Large Language Model for Science. Facebook.
- The DOI Foundation. (2026). *What is*. Opgehaald van doi.org: <https://www.doi.org/the-identifier/what-is-a-doi/>
- The National Library of the Netherlands. (sd). *Persistent Identifier Guide*. Opgehaald van Pidwijzer: <https://www.pidwijzer.nl/en>
- Utrecht, Universiteit. (sd). *Missie en visie*. Opgehaald van uu.nl: <https://www.uu.nl/organisatie/over-ons/missie-en-visie>
- Van Vliet, H. (2008). *Software Engineering: Principles and Practice Vol. 13*. Hoboken, NJ: John Wiley & Sons.
- Weller, J. (2023, September 17). *The Complete Guide to Gap Analysis*. Opgehaald van smartsheet: <https://www.smartsheet.com/gap-analysis-method-examples>

12 Bijlage 4: Testplan: Evaluatie LLM-classificatie

12.1 Opzet

12.1.1 Doel van de test

Het doel van deze test is het objectief evalueren van de herhaalbaarheid (repeatability) van verschillende Large Language Models (LLM's) en hun configuraties bij het genereren van onderzoekstopics. Omdat de ruwe output van de modellen in het Ricgraph-proces wordt gematcht aan een vaste, gestandaardiseerde conceptenlijst (OpenAlex), ligt de focus van de evaluatie op de stabiliteit van de uiteindelijke uitstroom. Een betrouwbaar model levert bij herhaalde generaties op dezelfde tekst consistent dezelfde set OpenAlex-topics op. Daarnaast wordt de invloed van parameters (zoals temperatuur) en prompting op deze herhaalbaarheid getoetst.

12.1.2 Testdata (Dataset)

Om de modellen te toetsen op een representatieve en realistische doorsnede van academische teksten, wordt een specifieke dataset samengesteld:

924 unieke publicaties (abstracts) afkomstig van onderzoekers van de Universiteit Utrecht (UU) uit het publicatiejaar 2024, geëxtraheerd uit de Ricgraph-database.

12.1.3 Testopstelling en Configuratie

Om een zuivere, wetenschappelijk verantwoorde meting te hebben, worden alle variabelen buiten het model en de specifieke testparameters gefixeerd. Het script wordt in totaal drie afzonderlijke keren uitgevoerd om de volgende configuraties te vergelijken:

1. **Baseline:** Uitvoering met temperature 0.2 en standaardprompting (mini-lm heeft geen temperatuurparameter, aangezien dit een embedding-only backend is).
2. **Lage temperatuur:** Uitvoering met de temperature parameter verlaagd naar 0.1, met dezelfde standaardprompt als scenario 1.
3. **Gestructureerde prompting:** Uitvoering met temperature 0.1. Deze specifieke waarde is behouden vanuit de tweede test, aangezien uit de resultaten bleek dat het model hiermee het beste presteerde en de minste fouten genereerde. Binnen deze iteratie is de prompt tevens opgesplitst in een expliciete system-role en user-role boodschap (in plaats van één ongestructureerde prompt), om te toetsen of deze rolstructurering de stabiliteit van de output verder beïnvloedt.

De vaste elementen per uitvoeringsronde zijn:

- **LLM-selectie:** Er wordt getest met drie specifieke backends: embedding_only (all-MiniLM-L6-v2), gpt-oss-120B, en Meta Llama 3 (8B Instruct).
- **Prompting & Formatting:** Elk LLM-backend (gpt-oss-120B en Llama 3 8B) krijgt per scenario exact dezelfde prompt, waarbij de outputbeperking (4 tot 10 topics) wordt meegegeven. De embedding_only-backend (mini-lm) kent geen promptings- of temperatuurparameter en wordt per scenario identiek uitgevoerd; deze backend dient primair als deterministische referentiewaarde (Jaccard = 1,0) voor de repeatability-vergelijking.

- **Generatieparameters:** Binnen een testscenario worden instellingen bevroren om herhaalbaarheid onder identieke omstandigheden te meten. Dit is niet van toepassing op mini-lm.

12.1.4 Uitvoering en Meetsystematiek (Repeatability)

De evaluatie is ontworpen om een balans te vinden tussen de breedte van de dataset en de diepte van de herhaalbaarheid:

- **Aantal runs en totale schaal:** Elk van de 924 abstracts wordt per LLM en per configuratiescenario precies 5 keer afzonderlijk geclassificeerd ($N_RUNS = 5$). Om de volledige omvang van de Proof of Concept inzichtelijk te maken, resulteert dit in de volgende opbouw:
 - 4.620 classificaties per afzonderlijk model, per configuratiescenario (924 abstracts x 5 runs).
 - 13.860 classificaties per configuratiescenario (4.620 runs x 3 modellen).
 - 41.580 classificaties in totaal (13.860 runs x 3 configuratiescenario's).
- **Matching:** De gegenereerde output van elke run wordt via een SentenceTransformer gematcht aan de OpenAlex-woordenlijst op basis van topic embeddings.
- **Evaluatiemetriek (Jaccard-index):** De uiteindelijke OpenAlex-termen worden per abstract onderling vergeleken via de Jaccard-index (de verhouding tussen de overlappende topics en het totaal aantal unieke topics).
- **Statistische verantwoording:** Met 5 runs per abstract ontstaan er per publicatie 10 unieke vergelijkingsparen per model. Over de gehele dataset resulteert dit in een statistisch gemiddelde, waarmee de prestaties tegen elkaar afgezet kunnen worden.

12.1.5 Dataverwerking en Resultaten

Tijdens de geautomatiseerde uitvoering van de Proof of Concept worden de handelingen en uitkomsten vastgelegd in een resultatenmap (results/repeatability/):

- **Testlogs en Metadata:** Per run wordt de output opgeslagen in een CSV-bestand. Bijbehorende metadata wordt opgeslagen in JSON-formaat (_meta.json). Hierbij worden de volgende metrics exact gelogd:
 - **Verwerkingstijd:** Totale en gemiddelde tijdsduur in seconden.
 - **Hardware-belasting:** Beschikbaarheid en specificaties van fysieke/logische CPU-cores, totaal RAM, en GPU-specificaties (aantal, namen, VRAM).
 - **Tokengebruik:** Gedetailleerde telling van prompt_tokens, completion_tokens, totaal aantal tokens, het gemiddelde per abstract en eventuele API-fouten.
- **Analyse en Overzicht:** De verzamelde data vormt de basis voor het uiteindelijke geaggregeerde overzicht (repeatability_summary.json en repeatability_summary_table.txt). Dit tabeloverzicht biedt een directe vergelijking langs drie evaluatiedimensies: repeatability (Jaccard-score), efficiëntie (verwerkingstijd en tokengebruik), en betrouwbaarheid (aantal API-fouten per scenario). Deze laatste dimensie is met name relevant bij de gpt-oss-120B backend, waar het foutenpercentage sterk varieerde tussen configuraties — een indicatie dat parameterkeuzes (temperatuur, promptstructuur) niet alleen de output-stabiliteit maar ook de uitvoeringsbetrouwbaarheid beïnvloeden.

12.2 Methode

12.2.1 Meetsystematiek: Paarsgewijze Jaccard-vergelijking

Om de herhaalbaarheid (repeatability) en stabiliteit van de LLM-classificaties te kwantificeren, is gekozen voor een paarsgewijze vergelijkingsmethode op basis van de Jaccard-index. Voor elk van de 924 abstracts in de dataset genereert een modelconfiguratie vijf onafhankelijke classificaties (runs). In plaats van de overlap over alle vijf de runs gelijktijdig te berekenen, worden de uitkomsten per abstract paarsgewijs vergeleken.

Bij vijf onafhankelijke runs resulteert dit in exact tien unieke vergelijkingsparen per abstract, conform de combinatieformule voor het kiezen van twee elementen uit een set van vijf:

$$C(5,2) = \frac{5!}{2!(5-2)!} = 10$$

Voor elk van deze tien paren wordt de Jaccard-index berekend, uitgedrukt als de verhouding tussen de doorsnede (overlappende topics) en de vereniging (alle unieke topics van dat paar):

$$J(A,B) = \frac{|A \cap B|}{|A \cup B|}$$

Vervolgens wordt het rekenkundig gemiddelde van deze tien Jaccard-scores berekend om tot één stabiliteitsscore per abstract te komen.

Verantwoording van de methode

Er is bewust afgezien van een methode waarbij de volledige doorsnede van alle vijf de runs tegelijkertijd wordt berekend. Een dergelijke alles-in-één vergelijking vereist dat een onderzoekstopic in álle vijf de iteraties exact overeenkomt om als overlap te tellen. Deze benadering is disproportioneel gevoelig voor uitschieters: een incidentele fluctuatie of afwijking in één enkele run straft de score van de overige, mogelijk identieke runs, onredelijk hard af.

De paarsgewijze methode isoleert dergelijke afwijkingen. Wanneer een model in vier van de vijf runs consistent presteert en slechts één keer afwijkt, behouden de paren zonder de afwijkende run een perfecte overlapscore (1.0). Het resulterende gemiddelde weerspiegelt de algemene consistentie van het model hierdoor veel nauwkeuriger. Deze werkwijze sluit aan bij de geldende statistische normen voor het meten van *test-retest reliability*, waarbij het aggregeren van paarsgewijze overeenkomsten een robuustere en realistischere weergave biedt van de voorspelbaarheid van het model in een productieomgeving.

12.2.2 Meetsystematiek: Inter-model Jaccard-vergelijking

Naast de repeatability-meting binnen één model wordt onderzocht in hoeverre de modellen onderling inhoudelijk verschillende classificaties opleveren, en zo ja, hoe groot dat verschil is. Waar de paarsgewijze Jaccard-vergelijking de interne consistentie van één backend meet (dezelfde tekst, meerdere runs, één model), meet de inter-model vergelijking de mate van overeenstemming tussen twee verschillende backends op dezelfde tekst.

Voor elk abstract wordt hiertoe, per modelkoppel (mini-lm–Gpt-oss, mini-lm–Llama, Gpt-oss–Llama), de Jaccard-index berekend tussen de gegenereerde topicsets, gemiddeld over de 5 beschikbare runs per model. Dit resulteert per configuratiescenario in drie gemiddelde inter-model Jaccard-scores.

Doel van deze vergelijking is vaststellen of modelkeuze een inhoudelijk relevante invloed heeft op de output van het classificatieproces. In andere woorden, maakt het uit welk model wordt ingezet, en

indien dat zo is, de omvang van dat verschil te kwantificeren. Een lage inter-model Jaccard-score (in combinatie met een hoge intra-model repeatability-score) wijst op modellen die weliswaar elk stabiel zijn in hun eigen output, maar structureel andere topics selecteren; dit heeft directe implicatie voor de keuze van het uiteindelijke productie-backend in Ricgraph, aangezien de modelkeuze dan niet vrijblijvend is.